

UNIVERSIDAD DE COSTA RICA
SISTEMA DE ESTUDIOS DE POSGRADO

MODELADO BAYESIANO DE EXTREMOS
ESPACIO-TEMPORALES DE PRECIPITACIÓN:
APLICACIONES EN ESTIMACIÓN DE MODELOS CON
COVARIABLES

Tesis sometida a la consideración de la Comisión del Programa
de Estudios de Posgrado en Matemática para optar al grado y
título de Maestría Académica en Matemática con énfasis en
Matemática Aplicada

CARLOS ALBERTO PASQUIER JARAMILLO

Ciudad Universitaria Rodrigo Facio, Costa Rica

2025

Dedicatoria

Agradecimientos

“Esta tesis fue aceptada por la Comisión del Programa de Estudios de Posgrado en Matemática de la Universidad de Costa Rica, como requisito parcial para optar al grado y título de Maestría Académica en Matemática con énfasis en Matemática Aplicada.”

Grado académico y nombre completo
Decano(a) o Representante del/de la Decano(a) Sistema de Estudios de Posgrado

Grado académico y nombre completo
Profesor(a) Guía

Grado académico y nombre completo
Lector(a)

Grado académico y nombre completo
Lector(a)

Grado académico y nombre completo
Director(a)/Representante Programa de Posgrado en Matemática

Nombre completo
Sustentante

Tabla de contenidos

Dedicatoria	ii
Agradecimientos	iii
Hoja de aprobación	iv
Resumen	vii
Lista de tablas	viii
Lista de figuras	ix
1. Introducción	1
1.1. Justificación	1
1.2. Planteamiento	2
1.3. Objetivos	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
2. Marco Teórico	4
2.1. Antecedentes	4
2.2. Inferencia Bayesiana	6
2.3. Métodos de Montecarlo basados en cadenas de Markov (MCMC)	7
2.4. Teoría de valor extremo	10
2.4.1. Teoría de los máximos	10
2.4.2. Teoría para los excedentes de umbral	15
2.4.3. Modelos Max-stable	19
2.5. Estadística espacial	25

2.5.1. Modelado de la dependencia espacial mediante modelos de cópulas	27
2.6. Redes Neuronales	30
2.6.1. Entrenamiento de Redes Neuronales: Descenso de Gradiente y Retropropagación	31
2.6.2. Capas densas	33
2.6.3. Capas Convolucionales (CNN - Conv2D)	34
2.6.4. Redes LSTM (Long Short-Term Memory)	36
2.7. Inferencia Amortizada	38
3. Formulación del modelo	45
4. Estimación de hiperparámetros	51
4.1. Arquitectura de las redes	52
4.2. Algoritmo de entrenamiento e inferencia	56
4.3. Evaluación del desempeño del modelo	57
5. Análisis experimental	61
5.1. Estudio de simulación	61
5.1.1. Propuesta	61
5.1.2. Modelo propuesto en Yadav et al. (2022)	65
5.2. Aplicación	71
5.2.1. Descripción de los datos	71
5.2.2. Modelación de precipitación usando el modelo espacio-temporal	73
6. Conclusiones	81
Bibliografía	82

Resumen

Esta investigación tiene como objetivo principal el desarrollo de un modelo bayesiano para la estimación de eventos extremos en modelos espacio-temporales que integren covariables, aplicado a datos de precipitación obtenidos del sistema CHIRPS en Costa Rica durante el periodo 2015-2022. En la introducción, se presentan las justificaciones y el planteamiento del problema, donde se destaca la importancia de abordar la gestión de fenómenos extremos de precipitación frente a los desafíos climáticos y ambientales actuales. El marco teórico incluye una revisión de la inferencia bayesiana, los métodos de Montecarlo basados en cadenas de Markov, la teoría de valor extremo, y la estadística espacial, entre otros temas relevantes, que sirven como base para la formulación del modelo.

El trabajo incluye una sección dedicada a la formulación del modelo bayesiano de extremos espacio-temporales y la estimación de sus parámetros. A través de técnicas avanzadas de redes neuronales, como redes LSTM y convolucionales, se proponen arquitecturas con el uso de la inferencia amortizada. La sección de análisis experimental presenta estudios de simulación para evaluar el rendimiento del modelo y su comparación con otros enfoques existentes. Además, se realiza una aplicación práctica utilizando datos de precipitación en Guanacaste, Costa Rica, mostrando cómo el modelo espacio-temporal puede mejorar la predicción y comprensión de los eventos extremos en el contexto regional.

Finalmente, en las conclusiones se resumen los hallazgos más importantes y las limitaciones del trabajo.

Lista de tablas

4.1. Arquitectura de la red de resumen R_α	54
4.2. Arquitectura para la red de resumen de R_X	55
5.1. Configuración de arquitecturas para cada modelo: cantidad de neuronas en la capa LSTM y número de redes invertibles.	63
5.2. Valores de los parámetros con identificación del modelo propuesto	64
5.3. Valores de los hiperparámetros con identificación del modelo Yadav et al. (2022) utilizando el método propuesto.	68
5.4. Valores de los hiperparámetros del modelo y método de estimación Yadav et al. (2022)	70
5.5. Error absoluto cuantílico media (EACCP) y Error cuadrático cuantílico media (ECCCP) en muestras de entrenamiento (entren.) y prueba. Valores más pequeños para ambas métricas indica mejor rendimiento, y el mejor modelo para cada criterio está en color azul.	76
5.6. Estadísticos de resumen posteriores para el modelo D4-M5	79

Lista de figuras

2.1. Izquierda: Aplicación de filtros a una imagen. Derecha: Explicación de la operación convolucional.	34
2.2. Flujo de una capa LSTM	37
5.1. Trazas de los hiperparámetros del estudio de simulación. Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones MCMC es de 10 mil (10 K). Las líneas verticales negras muestran los valores verdaderos.	66
5.2. Histograma de las muestras posteriores de los hiperparámetros en el estudio de simulación. Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones es de 10 mil (10 K). Las líneas horizontales negras muestran los valores verdaderos.	67
5.3. Trazas de todos los hiperparámetros del estudio de simulación del modelo de Yadav et al. (2022). Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones MCMC es de 10 mil (10 K). Las líneas verticales negras muestran los valores verdaderos.	69

5.4.	Histograma de las muestras posteriores de todos los hiperparámetros en el estudio de simulación del modelo de Yadav et al. (2022). Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones es de 10 mil (10 K). Las líneas horizontales negras muestran los valores verdaderos.	70
5.5.	Media y Desviación Estándar (DE) de la precipitación en mm para cada sitio.	72
5.6.	Distribución de los sitios de muestra de prueba y entrenamiento. Los sitios con triángulo son los que se aprecian en la figura 5.8	72
5.7.	Error absoluto cuantílico medio (EACCP) de precipitación en mm por locación utilizando los años 2020, 2021 y 2022 para varias combinaciones de modelo.	77
5.8.	Gráficos cuantil-cuantil de los sitios con forma triángulo en la figura 5.6 donde los cuantiles ajustados son simulados a partir del modelo D4-M5 , donde los hiperparámetros del modelo se estiman utilizando la media posterior correspondiente y los extremos de las franjas de color son los intervalos de credibilidad al 2.5 % y 97.5 %	78
5.9.	Niveles de retorno de precipitación en mm a distintos años utilizando el modelo D4-M5	80

1. Introducción

1.1. Justificación

La investigación sobre desastres naturales, como olas de calor, fuertes lluvias y tormentas de viento, es crucial en un contexto global marcado por el cambio climático. Según Pachauri et al. (2014), se ha observado un aumento significativo en la frecuencia de eventos extremos en los últimos cincuenta años, lo que resalta la necesidad de comprender y gestionar estos fenómenos de manera efectiva. Este trabajo busca abordar esta problemática al desarrollar una metodología para la estimación de eventos extremos, específicamente en el ámbito de las precipitaciones en Costa Rica, un país vulnerable a estos fenómenos.

Las consecuencias de los desastres naturales incluyen un incremento en inundaciones, fallos en cultivos y desplazamientos de poblaciones, así como efectos indirectos, como el aumento en costos de infraestructura y seguros. Al mejorar la comprensión de estos eventos, los objetivos de esta investigación proporcionan información valiosa que puede ser utilizada por autoridades locales y comunidades para la planificación y adaptación ante futuros desafíos ambientales.

La base teórica que sustenta este trabajo se fundamenta en modelos estadísticos avanzados que integran covariables relevantes para la estimación de extremos en contextos espacio-temporales. Este enfoque se alinea con las tendencias actuales en la investigación sobre el clima, donde se busca conectar diversas disciplinas, desde la climatología hasta la estadística y la salud pública. Aunque existe un gran volumen de

datos, la naturaleza poco común de los eventos extremos complica su análisis, haciendo esencial el desarrollo de modelos flexibles y robustos.

A nivel mundial, la investigación en este campo ha avanzado significativamente, con un enfoque creciente en la integración de datos meteorológicos y la modelización de riesgos. Este trabajo no solo se suma a estos esfuerzos, sino que también se centra en la aplicación práctica de la metodología en Costa Rica, contribuyendo a la resiliencia local frente a fenómenos climáticos adversos. En resumen, esta investigación pretende generar conocimiento aplicable y útil para la gestión de riesgos, lo cual es fundamental para mitigar los impactos de los desastres naturales en la región.

1.2. Planteamiento

La creciente frecuencia e intensidad de eventos climáticos extremos, como inundaciones y sequías, ha resaltado la necesidad urgente de desarrollar metodologías precisas para su análisis y predicción, especialmente en regiones vulnerables como Costa Rica. Aunque existe una abundancia de datos, la naturaleza rara de estos eventos representa un desafío significativo para la modelización y la inferencia estadística. Este problema se agrava por la complejidad del comportamiento espacial de los fenómenos meteorológicos, donde la variabilidad geográfica y temporal puede influir drásticamente en la estimación y la interpretación de los extremos.

Además, la integración de covariables relevantes en los modelos de extremos es esencial para mejorar la precisión de las predicciones y para comprender mejor los factores que contribuyen a estos eventos. Sin embargo, los métodos convencionales a menudo no consideran adecuadamente estas covariables, limitando así su efectividad en la estimación de eventos extremos. Por lo tanto, es crucial avanzar hacia enfoques más flexibles y robustos, como los modelos bayesianos, que puedan manejar la alta dimensionalidad y la incertidumbre asociadas con los datos espaciales.

Esta investigación busca abordar estas limitaciones mediante el desarrollo de un modelo para la estimación de extremos en modelos espacio-temporales que integre co-

variables, aplicada a datos de precipitación obtenidos de CHIRPS en Costa Rica durante el periodo 2015-2022. Con ello, se pretende mejorar la comprensión y gestión de fenómenos extremos de precipitación, contribuyendo a la planificación y adaptación frente a desafíos ambientales y climáticos.

Así, la pregunta central de esta investigación es: ¿cómo estimar eventos extremos usando modelos bayesianos espacio-temporales que integren covariables, aplicado en datos de precipitación de CHIRPS en regiones de Costa Rica entre 2015 y 2022?

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar un modelo bayesiano de extremos espacio-temporales que integre covariables y la respectiva metodología de estimación de parámetros para su posterior evaluación utilizando datos de precipitación de CHIRPS en regiones de Costa Rica entre el año 2015 y 2022

1.3.2. Objetivos específicos

1. Formular un modelo bayesiano de extremos espacio-temporales que pueda integrar covariables relevantes para la estimación.
2. Diseñar una metodología para la estimación de los parámetros del modelo propuesto.
3. Evaluar el desempeño del modelo formulado mediante estudios de simulación y aplicaciones prácticas utilizando datos precipitación de CHIRPS en regiones de Costa Rica entre el año 2015 y 2022.

2. Marco Teórico

2.1. Antecedentes

La modelación estadística de eventos extremos es fundamental para cuantificar riesgos en diversas aplicaciones ambientales. La mayoría de los datos ambientales tienen una naturaleza espacial o espacio-temporal, y los modelos que combinan la estadística espacial con la Teoría de Valores Extremos (TVE) ofrecen una forma matemática sólida para analizar el comportamiento marginal de estos eventos extremos, considerando su posible dependencia espacial o espacio-temporal. En Costa Rica, existen estudios como el de Guillén-Oviedo et al. (2020) donde se hace un comparativo de los parámetros estimados de la distribución generalizada de valores extremos para 103 estaciones meteorológica de América Central. Para Centroamérica, existen estudios como el de Alfaro-Córdoba et al. (2024) donde se evidencia tendencias positivas a través de los años, de varios índices de eventos extremos de precipitación

Las metodologías de bloque máximo (BM) y picos sobre umbral (POT, por sus siglas en inglés) son las dos principales técnicas para modelar los extremos de una distribución de probabilidad. A pesar de que aún se discuten sus ventajas y desventajas en Bücher y Zhou (2021), la metodología POT es generalmente preferida por no limitarse a trabajar solamente máximos al modelar directamente los eventos extremos.

En tiempos recientes, los modelos jerárquicos bayesianos han cobrado relevancia en este ámbito, gracias a su flexibilidad para representar complejas tendencias espacio-temporales y su facilidad para la inferencia en contextos de BM y POT, siempre que

los datos puedan considerarse condicionalmente independientes dado un conjunto de variables latentes con estructura espacial.

En particular, Cooley et al. (2007) emplearon procesos gaussianos para captar la dependencia espacial latente y las tendencias en datos de precipitación, utilizando un algoritmo de Monte Carlo basados en cadenas de Markov (MCMC, por sus siglas en inglés) relativamente sencillo para estimar distribuciones posteriores. De manera similar, Turkman et al. (2010) ajustaron modelos jerárquicos bayesianos a datos de incendios forestales espacio-temporales en Portugal aprovechando la inferencia basada en MCMC, mientras que Opitz et al. (2018) y Castro-Camilo et al. (2019) utilizaron la aproximación de Laplace integrada anidada (INLA) para ajustar un modelo a superaciones de umbral espacio-temporales. Más recientemente, Hazra et al. (2023) propusieron Max-and-Smooth, un algoritmo bayesiano aproximado diseñado para modelos gaussianos latentes extendidos, aplicándolo a un conjunto de datos de precipitaciones extremas a gran escala.

En Yadav et al. (2022) se propone un modelo jerarquico bayesiano flexible que incorpora la relación de dependencia entre locaciones mediante un Cópula Gaussiana y además, incorpora el uso covariables relevantes que afectan los valores extremos. Sin embargo, en ese trabajo se asume del todo independencia temporal y que además se observa dificultades en la mezcla del MCMC para la inferencia de los hiperparámetros.

Ante estas limitaciones de estimación con MCMC, existen alternativas para la estimación de parámetros libres de verosimilitud, Sainsbury-Dale et al. (2024) y Bülte et al. (2024) proponen utilizar redes neuronales bayesianas espaciales para analizar la dependencia espacial en extremos, haciendo uso de la redes para la estimación de parámetros de modelos como el de Schlather (2002), así mismo, Richards et al. (2023) expande este análisis para modelos populares para datos espaciales de excedencias sobre umbral los procesos como los r -Pareto (de Fondeville & Davison, 2018; Ferreira & de Haan, 2014), los procesos de puntos máximos invertidos (Wadsworth & Tawn, 2012), las mezclas aleatorias de escala/ubicación (Huser & Wadsworth, 2019; Huser et al., 2017) y el modelo de extremos condicionales espaciales (Wadsworth & Tawn, 2022). A pesar del

uso de las redes bayesianas, estos modelos ignoran la dependencia temporal que podría existir al utilizar muestras independientes, y además no se hace uso de covariables que podrían influir en los valores extremos. Es por eso que este trabajo es relevante ya que amplía el universo de modelos espaciales de extremos a un enfoque espacio-temporal, permitiendo capturar dependencias temporales.

2.2. Inferencia Bayesiana

La inferencia bayesiana se basa en la premisa de que las cantidades desconocidas o parámetros son variables aleatorias, mientras que los datos observados se consideran fijos. Así, el objetivo de la inferencia bayesiana es encontrar una distribución de probabilidad completa para los parámetros del modelo, tanto para aquellos observados como para los no observados. En este sentido, la inferencia bayesiana permite ajustar un modelo de probabilidad sobre un conjunto de datos y resumir este ajuste a través de la distribución de probabilidad correspondiente a los parámetros del modelo.

En el paradigma bayesiano, se denota $\pi(A)$ como la distribución marginal de A , $\pi(A | B)$ como la distribución condicional de A dado B , y $\pi(A, B)$ como la distribución conjunta de los eventos A y B . Además, en el modelo bayesiano, no solo se define el modelo de distribución $\pi(\mathbf{y} | \boldsymbol{\theta})$ para los datos observados $\mathbf{y} = (y_1, \dots, y_d)^T$ dado un vector de parámetros desconocidos $\boldsymbol{\theta} = (\theta_1, \dots, \theta_d)^T$, sino que asumimos que $\boldsymbol{\theta}$ es una variable aleatoria que sigue una distribución previa $\pi(\boldsymbol{\theta} | \boldsymbol{\psi})$, donde $\boldsymbol{\psi}$ es un vector de parámetros desconocidos.

A partir de esto, se pueden obtener inferencias sobre $\boldsymbol{\theta}$ mediante su distribución posterior $\pi(\boldsymbol{\theta} | \mathbf{y})$, que se expresa de acuerdo con el Teorema de Bayes:

$$\pi(\boldsymbol{\theta} | \mathbf{y}) = \frac{\pi(\mathbf{y} | \boldsymbol{\theta})\pi(\boldsymbol{\theta})}{\pi(\mathbf{y})},$$

aquí, la distribución posterior $\pi(\boldsymbol{\theta} | \mathbf{y})$ refleja la creencia actualizada sobre los parámetros $\boldsymbol{\theta}$ después de observar los datos $\mathbf{y}$. El término $\pi(\mathbf{y} | \boldsymbol{\theta})$ es la verosimilitud, que describe la probabilidad de observar los datos dado un valor específico de $\boldsymbol{\theta}$, y $\pi(\boldsymbol{\theta})$

es la distribución previa, que representa las creencias sobre los parámetros antes de observar los datos. El denominador $\pi(\mathbf{y})$ es la probabilidad marginal de los datos, que sirve para normalizar la distribución posterior.

La inferencia bayesiana se caracteriza por la capacidad de cuantificar explícitamente la incertidumbre. De hecho, una ventaja significativa de este enfoque es que puede manejar situaciones de sobreajuste, adaptándose mejor a los datos observados. Además, permite especificar modelos jerárquicos, donde los parámetros en distintos niveles pueden ser tratados como variables aleatorias, lo que a su vez facilita modelar dependencias complejas entre los datos observados.

Este proceso de análisis bayesiano generalmente se puede dividir en tres fases esenciales: primero, se debe definir un modelo de probabilidad completo, que es una distribución conjunta para todas las variables observables y no observables, consistente con el conocimiento previo sobre el problema y el proceso de recolección de datos. Segundo, se debe calcular la distribución posterior condicionada a los datos observados, que proporciona la probabilidad condicional de las variables de interés no observadas. Y tercero, se evalúa el ajuste del modelo y las implicaciones de la distribución posterior, analizando la validez de los resultados y su sensibilidad al modelo de probabilidad seleccionado.

De esta manera, la inferencia bayesiana permite realizar un análisis exhaustivo, cuantificando la incertidumbre inherente en las predicciones y permitiendo la introducción de estructuras de correlación entre los parámetros, como en los modelos jerárquicos, que añaden una capa adicional de flexibilidad y poder al modelado estadístico.

2.3. Métodos de Montecarlo basados en cadenas de Markov (MCMC)

Un desafío computacional al aplicar métodos bayesianos es que las integrales requeridas para realizar la inferencia suelen ser intratables para la mayoría de los problemas realistas y, por lo tanto, deben ser aproximadas numéricamente. En estas situaciones, las técnicas de MCMC se utilizan ampliamente para obtener una secuencia iterativa de

muestras de distribuciones de probabilidad multidimensionales que convergen hacia la distribución deseada. La secuencia de muestras forma una cadena de Markov y, después de varios pasos, la distribución de las muestras aproxima la verdadera distribución posterior.

Específicamente, los algoritmos MCMC funcionan generando una secuencia de muestras aleatorias de tal forma que, a medida que se producen más y más valores, la distribución de dichos valores se aproxima cada vez mejor a la distribución objetivo. El algoritmo Metropolis-Hastings de Monte Carlo mediante cadenas de Markov (MH-MCMC) (Metropolis et al. (1953); Hastings (1970)), es adecuado para entornos multidimensionales, siendo el más popular entre las diferentes técnicas MCMC debido a su implementación directa en diversos modelos jerárquicos bayesianos. Este algoritmo genera una nueva muestra candidata aleatoria a partir de una distribución de propuesta bien definida, y esta se convierte en el nuevo estado de la cadena siempre que la muestra candidata sea aceptada.

La muestra candidata $\mathbf{x}'$ se acepta con cierta probabilidad β (también llamada probabilidad de aceptación), la cual depende de la densidad de la propuesta $q(\mathbf{x}' | \mathbf{x})$ así como de la densidad posterior objetivo $\pi_{\text{post}}(\mathbf{x})$.

Los pasos detallados del algoritmo MH-MCMC se presentan a continuación:

1. Establecer los valores iniciales para el vector de parámetros $\mathbf{x}_0 = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^\top \in \mathbb{R}^n$.
2. Para cada iteración $t = 1, \dots, N$:
 - Simular una muestra candidata $\mathbf{x}_t$ desde la distribución de propuesta $q(\mathbf{x}_t | \mathbf{x}_{t-1})$.
 - Calcular el cociente de aceptación β como:

$$\beta = \min \left(1, \frac{\pi_{\text{post}}(\mathbf{x}_t) q(\mathbf{x}_{t-1} | \mathbf{x}_t)}{\pi_{\text{post}}(\mathbf{x}_{t-1}) q(\mathbf{x}_t | \mathbf{x}_{t-1})} \right) \quad (2.28)$$

- Aceptar la muestra candidata $\mathbf{x}_t$ con probabilidad β :

- Simular un número aleatorio uniforme $U \sim \mathcal{U}[0, 1]$.
- Si $U \leq \beta$, entonces aceptar la muestra candidata: $\mathbf{x}_{t+1} = \mathbf{x}_t$.
- Si $U > \beta$, entonces rechazar la muestra candidata: $\mathbf{x}_{t+1} = \mathbf{x}_{t-1}$.

La cadena de Markov resultante $\{\mathbf{x}_t; t = 0, 1, 2, \dots\}$ converge hacia su distribución estacionaria π_{post} . Además del algoritmo Metropolis-Hastings, otro método ampliamente utilizado dentro del enfoque MCMC es el algoritmo de muestreo de Gibbs (Casella y George, 1992), especialmente eficaz cuando la distribución conjunta es compleja, pero las distribuciones condicionales completas son conocidas y fáciles de muestrear.

El muestreo de Gibbs es un caso particular del algoritmo de Metropolis-Hastings donde la propuesta se toma directamente de la distribución condicional de cada variable, dada las demás. Esto significa que siempre se acepta la muestra propuesta, ya que proviene directamente de la distribución objetivo condicional.

El algoritmo se basa en la descomposición de la distribución conjunta $\pi(\mathbf{x})$ en sus distribuciones condicionales completas. Suponiendo un vector aleatorio multidimensional $\mathbf{x} = (x_1, x_2, \dots, x_d)$, el algoritmo genera muestras secuencialmente de cada variable x_i condicional a las demás variables fijadas en su valor actual:

1. Inicializar $\mathbf{x}^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_d^{(0)})$.
2. Para cada iteración $t = 1, 2, \dots, T$:
 - a) Muestrear $x_1^{(t)} \sim \pi(x_1 \mid x_2^{(t-1)}, x_3^{(t-1)}, \dots, x_d^{(t-1)})$
 - b) Muestrear $x_2^{(t)} \sim \pi(x_2 \mid x_1^{(t)}, x_3^{(t-1)}, \dots, x_d^{(t-1)})$
 - c) $\vdots$
 - d) Muestrear $x_d^{(t)} \sim \pi(x_d \mid x_1^{(t)}, x_2^{(t)}, \dots, x_{d-1}^{(t)})$

Una de las ventajas principales del algoritmo de Gibbs es su simplicidad cuando las condicionales completas son conocidas y tratables. Sin embargo, una limitación clave es que su aplicación directa requiere la capacidad de muestrear de cada una de las condicionales, lo cual puede no ser posible en todos los modelos. A pesar de esta

limitación, el muestreo de Gibbs es ampliamente usado en modelos jerárquicos y redes bayesianas, donde las condicionales suelen tener formas estándar.

2.4. Teoría de valor extremo

Existen varios libros de texto y artículos de revisión que proporcionan una descripción detallada de los fundamentos matemáticos de los modelos de valores extremos, ver, por ejemplo, Ledbetter et al. (1983); Coles (2001); Reiss y Thomas (2007); A. C. Davison et al. (2012); Cooley et al. (2012); A. Davison y Huser (2015); A. Davison et al. (2019). Fisher y Tippett (1928) fueron los primeros en caracterizar la distribución asintótica del máximo muestral, y sus argumentos fueron completados y formalizados más tarde por Gnedenko (1943). El uso más extenso del modelo BM para aplicaciones estadísticas comenzó en la década de 1950, y Gumbel (1958) tuvo un papel influyente en el avance y promoción de la metodología. La inferencia de máxima verosimilitud para los máximos por bloques basada en el modelo generalizado de valor extremo (GEV) fue considerada inicialmente por Prescott y Walden (1980). Alternativamente, la otra forma de definir los eventos extremos es en términos de superaciones de umbral, donde esta metodología tiene una larga historia en la literatura hidrológica. Los argumentos de la teoría de valores extremos conducen al modelo generalizado de Pareto (GP) originalmente definido por Pickands III et al. (1975), aunque las superaciones de umbral se asumieron inicialmente como una distribución exponencial, que es un caso especial del modelo GP. En A. Davison y Smith (1990) se proporciona una descripción detallada de las propiedades estadísticas del método de POT. El principal objetivo de esta sección es introducir la teoría univariada de los máximos y las superaciones de umbral.

2.4.1. Teoría de los máximos

Sea $Y_1, \dots, Y_n$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d) con función de distribución F . El enfoque de máximos por bloques

se centra en modelar el comportamiento estadístico de

$$M_n = \max\{Y_1, \dots, Y_n\}$$

para grandes n . La variable aleatoria M_n generalmente denota el máximo del proceso sobre un bloque de n observaciones, por ejemplo, M_n corresponde al máximo anual si n es el número de observaciones en un año. De manera directa, la distribución de M_n puede escribirse como:

$$\Pr(M_n \leq z) = \Pr(Y_1 \leq z, \dots, Y_n \leq z) = F(z)^n.$$

En la práctica, la función de distribución F es desconocida, y la aproximación de F por sus estimaciones a partir de los datos observados conduce a discrepancias sustanciales en las estimaciones de M_n . Como solución alternativa, se puede suponer que F es desconocida y luego buscar familias de modelos que aproximen F_n y que puedan ser estimadas solo con datos extremos o raros. Esto es similar al Teorema Central del Límite (TCL), donde la distribución normal aproxima la distribución de las medias muestrales para un tamaño de muestra grande. Por lo tanto, los argumentos para derivar modelos apropiados para F_n son esencialmente un análogo de valores extremos del TCL.

Sea z^+ el punto final superior de F . Entonces, $F_n(z) \rightarrow 0$ para todo $z < z^+$. Por lo tanto, para evitar la degeneración de M_n en z^+ , es decir, que tome un único valor con probabilidad 1 se debe realizar una renormalización lineal de la variable M_n :

$$M_n^* = \frac{M_n - b_n}{a_n} \tag{2.1}$$

donde $\{a_n > 0\}$ y $\{b_n\}$ son sucesiones apropiadas de constantes, que estabilizan la localización y escala de M_n^* , respectivamente, a medida que n aumenta. Por lo tanto, se busca distribuciones límite de M_n^* con elecciones apropiadas de las sucesiones de constantes $\{a_n\}$ y $\{b_n\}$, en lugar de M_n . Toda la gama de distribuciones límite posibles para M_n^* de (2.1) está dada por el Teorema de Tipos Extremales

Teorema 2.1 (Teorema de Tipos Extremales). *Si existen sucesiones de constantes $\{a_n > 0\}$ y $\{b_n\}$, tal que*

$$\Pr \left(\frac{M_n - b_n}{a_n} \leq z \right) \rightarrow G(z) \quad \text{cuando } n \rightarrow \infty, \quad (2.2)$$

donde G es una función de distribución no degenerada, entonces G pertenece a una de las siguientes familias de distribuciones:

I:

$$G(z) = \exp \left(- \exp \left(- \left(\frac{z - b}{a} \right) \right) \right), \quad -\infty < z < \infty;$$

II:

$$G(z) = \begin{cases} 0, & z \leq b; \\ \exp \left(- \left(\frac{z - b}{a} \right)^{-\alpha} \right), & z > b; \end{cases}$$

III:

$$G(z) = \begin{cases} \exp \left(- \left(\frac{z - b}{a} \right)^{-\alpha} \right), & z < b; \\ 1, & z \geq b; \end{cases}$$

para parámetros $a > 0$, b , y , para las familias II y III, $\alpha > 0$.

Estas tres clases de distribuciones se conocen colectivamente como las distribuciones de valores extremos de tipo I, II y III, popularmente conocidas como las familias de Gumbel, Fréchet y Weibull, respectivamente. Cada familia consiste en los parámetros de localización b y escala a , y las familias Fréchet y Weibull incluyen un parámetro adicional conocido como el parámetro de forma α . Las tres familias de distribuciones (Gumbel, Fréchet y Weibull) pueden fusionarse en una sola familia de modelos con una función de distribución de la forma:

$$G(z) = \exp \left(- \left(1 + \xi \left(\frac{z - \mu}{\sigma} \right)^{-\frac{1}{\xi}} \right) \right), \quad -\infty < \mu; \quad \xi < \infty; \quad \sigma > 0, \quad \mu \in \mathbb{R}, \quad (2.3)$$

que está definida en el conjunto $\left\{z : 1 + \xi \left(\frac{z-\mu}{\sigma}\right) > 0\right\}$. Esto se conoce como la familia de distribuciones generalizadas de valores extremos (GEV). La distribución GEV en (2.3) tiene los siguientes tres tipos de colas:

- i) cuando $\xi > 0$, la distribución GEV es de cola pesada con soporte $z > \mu - \frac{\sigma}{\xi}$;
- ii) cuando $\xi < 0$, la distribución GEV tiene una cola acotada con soporte $z < \mu - \frac{\sigma}{\xi}$;
- iii) para $\xi \rightarrow 0$, la distribución GEV es de cola ligera con soporte en toda la línea real $\mathbb{R}$.

Las familias Gumbel, Fréchet y Weibull se obtienen cuando $\xi \rightarrow 0$, $\xi > 0$ y $\xi < 0$, respectivamente. Al invertir la ecuación 2.3 tal que $G(z_p) = 1 - p$, se puede obtener las estimaciones de los cuantiles extremos de las distribuciones del máximo anual, y se da como

$$z_p = \begin{cases} \mu - \frac{\sigma}{\xi} (1 + \log(1 - p)^\xi), & \xi \neq 0; \\ \mu - \sigma \log(-\log(1 - p)), & \xi = 0; \end{cases} \quad (2.4)$$

Formalmente, z_p se llama el nivel de retorno asociado con el período de retorno $\frac{1}{p}$. Se espera que el nivel z_p sea superado en promedio una vez cada $\frac{1}{p}$ años. En otras palabras, con probabilidad p , z_p es superado por el máximo anual en cualquier año particular.

Inferencia de máxima verosimilitud para la distribución GEV

En la práctica, la aplicación de la distribución GEV consiste en dividir los datos en bloques disjuntos, cada uno con tamaño n , y luego ajustar la GEV al conjunto de máximos por bloque. La precisión de esta implementación depende de la elección del tamaño del bloque, ya que un tamaño de bloque mayor da lugar a un tamaño de muestra más pequeño (alta varianza de estimación) y un tamaño de bloque más pequeño puede resultar en una mala aproximación por el teorema límite 2.3, lo que lleva a sesgo en la estimación y extrapolación. Por lo tanto, la elección de los bloques generalmente representa una compensación entre el sesgo y la varianza. A lo largo de los años, se han propuesto varias técnicas para la inferencia y la estimación de parámetros

de los modelos de valores extremos. Cada una tiene sus ventajas y desventajas, pero las técnicas basadas en verosimilitud son las más conocidas debido a sus atractivas propiedades para grandes muestras y alta flexibilidad.

Sea $Y_1, Y_2, \dots, Y_{nm}$ observaciones i.i.d., y $Z_i = \max\{Y_{(i-1)n+1}, \dots, Y_{in}\}$, $i = 1, \dots, m$, los máximos por bloque con bloques de longitud n . Bajo la suposición de que los máximos por bloque $Z_1, \dots, Z_m$ son variables independientes provenientes de una distribución GEV, la log-verosimilitud para los parámetros de la GEV cuando $\xi \neq 0$ es

$$\ell(\mu, \sigma, \xi) = -m \log \sigma - \frac{1 + 1/\xi}{\xi} \sum_{i=1}^m \log \left(1 + \xi \frac{Z_i - \mu}{\sigma} \right) - \sum_{i=1}^m \left(1 + \xi \frac{Z_i - \mu}{\sigma} \right)^{-\frac{1}{\xi}}, \quad (2.5)$$

siempre que

$$1 + \xi \left(\frac{Z_i - \mu}{\sigma} \right) > 0, \quad \text{para } i = 1, \dots, m. \quad (2.6)$$

Y para $\xi = 0$,

$$\ell(\mu, \sigma) = -m \log \sigma - \sum_{i=1}^m \frac{Z_i - \mu}{\sigma} - \sum_{i=1}^m \exp \left(-\frac{Z_i - \mu}{\sigma} \right). \quad (2.7)$$

Desafortunadamente, no existen expresiones en forma cerrada para maximizar el par de ecuaciones (2.6) y (2.7) con respecto a los parámetros de la GEV $(\mu, \sigma, \xi)^T$, pero para cualquier conjunto de datos dado, es sencillo usar los algoritmos de optimización numérica estándar para optimizar la log-verosimilitud. Al realizar la optimización de (2.5), se debe implementar cuidadosamente los algoritmos numéricos para el conjunto de parámetros que garantice que no haya violación de (2.6).

Es fundamental resaltar que, debido a la restricción (2.6), la función de verosimilitud de la distribución GEV no cumple con las condiciones de regularidad, lo que significa que las propiedades asintóticas habituales del estimador de máxima verosimilitud no se aplican en este caso. Específicamente, el punto final de la distribución GEV está determinado por los valores de sus parámetros: cuando $\xi < 0$, el punto final superior es $\mu - \frac{\sigma}{\xi}$, mientras que cuando $\xi > 0$, se convierte en un punto final inferior. Este comportamiento infringe las condiciones de regularidad necesarias para que se validen

los resultados asintóticos convencionales en verosimilitud. Smith (1985) abordó este problema en detalle y presentó los siguientes hallazgos:

- Si $\xi > -0,5$, los estimadores de máxima verosimilitud son regulares y, por lo tanto, poseen las propiedades asintóticas estándar;
- Si $-1 < \xi < -0,5$, los estimadores de máxima verosimilitud están generalmente disponibles, pero no son regulares, por lo que no cumplen con las propiedades asintóticas comunes;
- Si $\xi < -1$, no se dispone de estimadores de máxima verosimilitud.

El escenario $\xi \leq -0,5$ es poco frecuente en la práctica del modelado de valores extremos, ya que corresponde a distribuciones GEV con una cola superior muy corta y limitada, lo que hace que las restricciones teóricas del enfoque de máxima verosimilitud no sean demasiado restrictivas en la mayoría de los casos. Sujeto a las condiciones previas sobre ξ , la distribución límite de $(\hat{\mu}, \hat{\sigma}, \hat{\xi})^T$ sigue una distribución normal multivariada, con un vector de medias $(\mu, \sigma, \xi)^T$ y una matriz de varianza-covarianza que es la inversa de la matriz de información observada, evaluada en los valores estimados de máxima verosimilitud. Para estimar el nivel de retorno z_p , se sustituyen las estimaciones de máxima verosimilitud de los parámetros de la GEV en la expresión (2.7), para $0 < p < 1$. Los intervalos de confianza para z_p pueden calcularse mediante el método Delta, o de preferencia, utilizando verosimilitud perfilada, que considera la asimetría significativa cuando p es pequeño (es decir, para períodos de retorno grandes $1/p$).

2.4.2. Teoría para los excedentes de umbral

Modelar los máximos por bloque puede llevar a un uso ineficiente de los datos si se cuentan con otras observaciones extremas disponibles. Además, en ciertas aplicaciones, es crucial considerar y modelar toda la serie temporal, como por ejemplo las observaciones horarias o diarias, en lugar de segmentar los datos en bloques. Sea Y una variable aleatoria con función de distribución F . Entonces, es natural considerar que un evento

Y es extremo si Y supera algún umbral alto u , y la probabilidad condicional definida a continuación proporciona el comportamiento estocástico de estos eventos:

$$F_u(y) = \Pr\{Y \leq u + y \mid Y > u\} = \frac{F(u + y) - F(u)}{1 - F(u)}, \quad y > 0, \quad (2.8)$$

La función F_u caracteriza la distribución de la superación $Y - u$ sobre un umbral u , dado que supera el nivel u . En aplicaciones prácticas, la distribución F es desconocida y, por lo tanto, también lo es la distribución de los excedentes en (2.8). Por lo tanto, se buscamos aproximaciones que sean ampliamente aplicables para valores altos de umbral.

El Teorema de Pickands-Balkema-de Haan es conocido como uno de los teoremas en la TVE. Este teorema caracteriza el posible límite para F_u definido en (2.8), a medida que u se aproxima a los puntos finales superiores.

Teorema 2.2. *Sea $Y_1, Y_2, \dots$ una sucesión de variables aleatorias i.i.d. con una función de distribución marginal F , y sea F_u su función de distribución condicional de excedentes en (2.8). Entonces, en Pickands III et al. (1975) se demuestra que para una amplia clase de funciones de distribución subyacentes F , F_u es aproximada bien para u grandes por la distribución Pareto generalizada (GP) definida como*

$$E(x) = \begin{cases} 1 - \left(1 + \frac{\xi x}{\beta}\right)^{-1/\xi}, & \text{si } \xi \neq 0, \\ 1 - \exp\left(-\frac{x}{\beta}\right), & \text{si } \xi = 0, \end{cases} \quad (2.9)$$

donde el soporte es $x \geq 0$ cuando $\xi \geq 0$, y $0 \leq x \leq -\frac{\beta}{\xi}$ cuando $\xi < 0$, donde ξ y $\beta > 0$ son los parámetros de forma y escala de la distribución GP, respectivamente.

Un resultado importante en la TVE es la dualidad asintótica entre las familias GEV y GP. Más precisamente, existe una relación uno a uno entre los parámetros de la distribución GP de los excedentes por umbral y la distribución GEV de los máximos por bloque. Esto se ilustra en el siguiente teorema.

Teorema 2.3. *Sea $Y_1, Y_2, \dots$ una sucesión de variables aleatorias i.i.d. con función de distribución F , y F cumpla el teorema 2.1, de modo que para grandes n :*

$$\Pr(M_n \leq z) \approx G(z),$$

donde $M_n = \max(Y_1, \dots, Y_n)$ y G es una distribución GEV dada en 2.3. Se denota de manera arbitraria un término en la sucesión Y_i como Y , luego, para u suficientemente grande, la función de distribución de $(Y - u)$, condicionada al evento $Y > u$, puede aproximarse por

$$E(x) = 1 - \left(1 + \frac{\xi x}{\beta}\right)^{-1/\xi}, \quad \beta = \sigma + \xi(u - \mu), \quad (2.10)$$

que está definida en $\{x : x > 0 \text{ y } (1 + \frac{\xi x}{\beta}) > 0\}$, y $(\mu, \sigma, \xi)^T$ son los parámetros de la distribución GEV G .

La familia de distribuciones definida por la ecuación (2.10) corresponde a la del teorema 2.3 y, por lo tanto, es una GP, lo que permite asegurar que si los máximos por bloque tienen una distribución aproximada G , entonces los excedentes por umbral tienen una distribución aproximada relacionada dentro de la familia GP. En particular, el parámetro de forma ξ en (2.10) es igual al parámetro de forma de la GEV en (2.3).

En la práctica, la selección del umbral u está relacionada con la aproximación de la cola en (2.9) y es comparable a la elección del tamaño de bloque en el enfoque de máximos por bloque. Hay dos métodos comunes para determinar el umbral óptimo: el primero implica un análisis exploratorio realizado antes de la estimación del modelo, y el segundo se basa en evaluar las estimaciones de los parámetros ajustadas a diferentes valores de umbral. En particular, el primer método utiliza la media de la distribución GP, conocida también como el gráfico de vida residual media, que se construye a partir de pares de puntos.

$$\left(u, \frac{1}{n_u} \sum_{i=1}^k (y_i - u)\right), \quad u < y_{\max},$$

donde $y_1, \dots, y_k$ son las k observaciones ordenadas que exceden el umbral u y $y_{\max}$ es el valor máximo de y_i . El umbral óptimo u ocurre alrededor del punto donde el gráfico de vida residual media se estabiliza. El segundo método para seleccionar el umbral es estimar los parámetros del modelo en diferentes umbrales y elegir el umbral más bajo u , más allá del cual los parámetros de forma estimados son aproximadamente constantes.

Después de determinar el umbral u , los parámetros de la distribución GP pueden estimarse mediante máxima verosimilitud. Más explícitamente, sean $y_1, \dots, y_k$ los k puntos de datos (excesos) sobre el umbral u , entonces utilizando (2.9), la log-verosimilitud para $\xi \neq 0$ es

$$\ell(\beta, \xi) = -k \log(\beta) - (1 + 1/\xi) \sum_{i=1}^k \log \left(1 + \frac{\xi y_i}{\beta} \right),$$

siempre que $(1 + \frac{\xi y_i}{\beta}) > 0$, y para $\xi = 0$,

$$\ell(\beta) = -k \log(\beta) - \frac{1}{\beta} \sum_{i=1}^k y_i.$$

Dado que la log-verosimilitud no tiene una expresión analítica, deben aplicarse técnicas numéricas para encontrar las estimaciones de los parámetros para la distribución GP.

Generalmente, los cuantiles o niveles de retorno son más convenientes para interpretar los modelos de valores extremos que los valores individuales de los parámetros. Sea $GP(\beta, \xi)$ un modelo adecuado para los excedentes de umbral de un umbral u por una variable Y . Entonces,

$$\Pr(Y > y) = \theta_u \left(1 + \frac{\xi(y - u)}{\beta} \right)^{-\frac{1}{\xi}}, \quad \theta_u = \Pr(Y > u).$$

Sea y_m el nivel que se supera en promedio cada m observaciones, entonces y_m puede obtenerse resolviendo

$$\theta_u \left(1 + \frac{\xi(y_m - u)}{\beta} \right)^{-1/\xi} = \frac{1}{m}.$$

Tras algunos arreglos, obtenemos

$$y_m = u + \frac{\beta}{\xi} \left((m\theta_u)^\xi - 1 \right), \quad \text{para } \xi \neq 0, \quad (2.10)$$

bajo la condición de que m sea lo suficientemente grande como para que $y_m > u$. De manera similar, para $\xi = 0$,

$$y_m = u + \sigma \log(m\theta_u). \quad (2.11)$$

Por definición, y_m se considera el nivel de retorno para m observaciones. En la práctica, resulta más útil expresar los niveles de retorno en una escala anual. Sea n_y el número de observaciones por año, entonces el nivel de retorno a N años se obtiene al fijar $m = N \cdot n_y$ en las ecuaciones (2.10) y (2.11). Las estimaciones de máxima verosimilitud para estos niveles de retorno se obtienen al sustituir las estimaciones de los parámetros $(\hat{\beta}, \hat{\xi})^T$ de la distribución GP en dichas ecuaciones, mientras que la evaluación de la incertidumbre puede realizarse utilizando el método Delta o mediante verosimilitud perfilada.

2.4.3. Modelos Max-stable

En el contexto univariado, la distribución GEV es la única distribución max-sstable, por lo que es natural buscar una posible extensión al caso multivariado. Al tratar con modelos multivariados de valores extremos, una suposición básica es que las distribuciones marginales univariadas deben ser GEV (es decir, una de las distribuciones clásicas de valores extremos: Fréchet, Gumbel o Weibull). Sin embargo, la gama de posibles estructuras de dependencia es mucho más amplia, y su caracterización es más complicada.

Sea $Y_i = (Y_{i1}, \dots, Y_{id})^T$, $i = 1, \dots, n$, un conjunto de vectores aleatorios i.i.d. en dimensión d . Se considera el máximo muestral M_{nj} para cada componente $j = 1, \dots, d$, y se agrupa en un nuevo vector aleatorio $\mathbf{M}_n$ de la siguiente forma:

$$\mathbf{M}_n = (M_{n1}, \dots, M_{nd})^T, \quad M_{nj} = \max(Y_{1j}, \dots, Y_{nj}).$$

Nótese que el punto M_n no necesariamente pertenece a la muestra observada, ya

que los máximos en diferentes componentes pueden ocurrir en diferentes momentos. Si se supone que existen sucesiones de vectores $(a_{n1}, \dots, a_{nd})^T \in \mathbb{R}_+^d$ y $(b_{n1}, \dots, b_{nd})^T \in \mathbb{R}^d$ tales que:

$$\left(\frac{M_{n1} - b_{n1}}{a_{n1}}, \dots, \frac{M_{nd} - b_{nd}}{a_{nd}} \right)^T \xrightarrow{D} (Z_1, \dots, Z_d)^T \stackrel{D}{\sim} G,$$

donde las distribuciones marginales $G_1, \dots, G_d$ de las variables límite $Z_1, \dots, Z_d$, respectivamente, son no degeneradas. Por el teorema 2.1, las marginales $Z_j \sim \text{GEV}(\mu_j, \beta_j, \xi_j)$ para $j = 1, \dots, d$, donde $\mu_j \in \mathbb{R}$, $\beta_j > 0$, $\xi_j \in \mathbb{R}$ son los parámetros de ubicación, escala y forma para cada componente j .

Las variables Z_j se pueden transformar a marginales Fréchet mediante la siguiente transformación:

$$\tilde{Z}_j = \left(1 + \xi_j \left(\frac{Z_j - \mu_j}{\beta_j} \right) \right)^{1/\xi_j} := t_j(Z_j).$$

Entonces, $\tilde{Z}_j \sim \text{GEV}(1, 1, 1) \equiv \text{Fréchet}(1)$, es decir,

$$\Pr(\tilde{Z}_j \leq z) = \exp(-1/z), \quad z > 0.$$

Teorema 2.4 (Distribución límite para máximos por componente.). *Sea $(\tilde{M}_{n1}, \dots, \tilde{M}_{nd})^T$ el vector de máximos por componente de vectores aleatorios i.i.d. $(Y_{i1}, \dots, Y_{id})^T$, transformados para tener distribuciones marginales Fréchet estándar. Si se cumple que*

$$\Pr \left(n^{-1} \tilde{M}_{n1} \leq z_1, \dots, n^{-1} \tilde{M}_{nd} \leq z_d \right) \xrightarrow{D} \tilde{G}(z_1, \dots, z_d), \quad z_1, \dots, z_d > 0, \quad (2.12)$$

donde $\tilde{G}$ es no degenerada, entonces

$$\tilde{G}(z_1, \dots, z_d) = \exp \{ -V(z_1, \dots, z_d) \}, \quad z_1, \dots, z_d > 0, \quad (2.13)$$

y la función V , llamada función exponente, está dada por

$$V(z_1, \dots, z_d) = d \int_{\mathbf{s}_d} \max \left(\frac{\omega_1}{z_1}, \dots, \frac{\omega_d}{z_d} \right) dQ(\omega_1, \dots, \omega_d), \quad (2.14)$$

para cierta distribución espectral Q definida sobre el simplicial de dimensión $(d-1)$:

$$\mathbf{s}_d = \left\{ (\omega_1, \dots, \omega_d)^T \in [0, 1]^d : \sum_{j=1}^d \omega_j = 1 \right\},$$

y que satisface las restricciones de media:

$$\int_{\mathbf{s}_d} \omega_j dQ(\omega) = \frac{1}{d}, \quad j = 1, \dots, d.$$

Toda la información sobre la dependencia extrema está contenida en la función exponente V o en la distribución espectral Q .

En el contexto espacial, se puede extender el concepto de max-estabilidad a procesos estocásticos. Los procesos max-stables son los análogos funcionales de las distribuciones max-stables.

Un proceso estocástico $Z(\mathbf{s})$, $\mathbf{s} \in S \subset \mathbb{R}^2$, se denomina *max-stable* si para cualquier conjunto finito de ubicaciones $D = \{\mathbf{s}_1, \dots, \mathbf{s}_d\} \subset S$, cualquier función $z(\mathbf{s})$, y para todo $n = 1, 2, \dots$, existen funciones $a_n(\mathbf{s}) > 0$ y $b_n(\mathbf{s})$ tales que:

$$\Pr \{ Z(\mathbf{s}) \leq a_n(\mathbf{s})z(\mathbf{s}) + b_n(\mathbf{s}), \mathbf{s} \in D \}^n = \Pr \{ Z(\mathbf{s}) \leq z(\mathbf{s}), \mathbf{s} \in D \}.$$

De manera alternativa, sea $Z_n(\mathbf{s}) = \max_{i=1, \dots, n} Y_i(\mathbf{s})$, donde $Y_i(\mathbf{s})$, $\mathbf{s} \in S \subseteq \mathbb{R}^2$, $i = 1, 2, \dots$, es una sucesión de procesos aleatorios i.i.d., y si se supone que existen sucesiones de funciones $a_n(\mathbf{s}) > 0$ y $b_n(\mathbf{s})$ tales que, cuando $n \rightarrow \infty$:

$$a_n(\mathbf{s})^{-1} \{ Z_n(\mathbf{s}) - b_n(\mathbf{s}) \} \xrightarrow{D} Z(\mathbf{s}),$$

donde el proceso $Z(\mathbf{s})$ tiene marginales no degeneradas. Entonces, $Z(\mathbf{s})$ se denomina *proceso max-stable*.

Por ejemplo, si $Z(\mathbf{s})$ tiene marginales Fréchet estándar, es decir,

$$\Pr\{Z(\mathbf{s}) \leq z\} = \exp(-1/z), \quad z > 0,$$

se puede tomar $a_n(\mathbf{s}) = n$ y $b_n(\mathbf{s}) = 0$, y las distribuciones finito-dimensionales toman la forma dada en la ecuación (2.13). Tales modelos límite max-stables están caracterizados por *cóputas de valores extremos*.

En de Haan (1984) se da una caracterización completa de los valores extremos multivariados, donde la dependencia extrema se explica en términos de medidas espectrales definidas sobre un subconjunto de la esfera unitaria. Bajo condiciones suaves, cualquier proceso max-stable $\{Z(\mathbf{s}), \mathbf{s} \in S\}$, con márgenes Fréchet estándar y trayectorias continuas, puede representarse como:

$$Z(\mathbf{s}) = \sup_{i \geq 1} \frac{W_i(\mathbf{s})}{P_i}, \quad \mathbf{s} \in S, \quad (2.15)$$

donde $W, W_1, W_2, \dots$ son procesos estocásticos i.i.d. no negativos tales que $\mathbb{E}(W(\mathbf{s})) = 1$ para todo $\mathbf{s} \in S$, y $\mathbb{E}(\sup_{\mathbf{s} \in S} W(\mathbf{s})) < \infty$, y los P_i son los puntos de un proceso de Poisson de tasa unitaria sobre $\mathbb{R}^+$. Recíprocamente, cualquier proceso que admita la representación (2.15) es max-stable con márgenes Fréchet estándar.

La distribución conjunta en d ubicaciones $\mathbf{s}_1, \dots, \mathbf{s}_d$ puede expresarse como:

$$\Pr\{Z(\mathbf{s}_1) \leq z_1, \dots, Z(\mathbf{s}_d) \leq z_d\} = \exp\{-V(z_1, \dots, z_d)\}, \quad (2.16)$$

donde la función V está dada por:

$$V(z_1, \dots, z_d) = \mathbb{E} \left(\max_{j=1, \dots, d} \left(\frac{W(\mathbf{s}_j)}{z_j} \right) \right). \quad (2.17)$$

Para estas d ubicaciones $\mathbf{s}_1, \dots, \mathbf{s}_d$ y su correspondiente función exponente $V(z_1, \dots, z_d)$, se define el *coeficiente extremal* $\theta_d \in [1, d]$ como:

$$\theta_d(\mathbf{s}_1, \dots, \mathbf{s}_d) = V(1), \quad (2.18)$$

donde $\mathbf{1} = (1, \dots, 1)^T$ es el vector de unos de longitud d . El coeficiente extremal es un resumen de la dependencia extrema:

- Si $\theta_d(\mathbf{s}_1, \dots, \mathbf{s}_d) = 1$, existe **dependencia perfecta** entre las variables $Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_d)$.
- Si $\theta_d(\mathbf{s}_1, \dots, \mathbf{s}_d) = d$, las variables son **independientes**.

Más precisamente, $\theta_d(\mathbf{s}_1, \dots, \mathbf{s}_d)$ corresponde al número efectivo de variables independientes entre $Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_d)$.

Es posible obtener diversos modelos max-stables mediante distintas elecciones del proceso $W(\mathbf{s})$. En Smith (1990), se toma $W(\mathbf{s}) = \phi_{\Sigma}(\mathbf{s} - U)$, donde U es un punto de un proceso de Poisson homogéneo con tasa unitaria sobre S , y $\phi_{\Sigma}(\cdot)$ es la función de densidad gaussiana con matriz de covarianza Σ .

En este caso, el máximo sobre un número ilimitado de “tormentas” centradas en puntos aleatorios U y con amplitud $1/P_i$ puede interpretarse como el valor del proceso max-stable en $\mathbf{s}$. Este modelo es conocido como el *modelo de Smith*.

Sea $Z(\mathbf{s})$ y $Z(\mathbf{s} + \mathbf{h})$ la realización del proceso aleatorio Z en las ubicaciones espaciales $\mathbf{s}$ y $\mathbf{s} + \mathbf{h}$, separadas por un desfase espacial $\mathbf{h}$. Entonces, la función exponente bivariada correspondiente está dada por:

$$V(z_1, z_2) = \frac{1}{z_1} \Phi \left(\frac{a}{2} + \frac{1}{a} \log \frac{z_2}{z_1} \right) + \frac{1}{z_2} \Phi \left(\frac{a}{2} + \frac{1}{a} \log \frac{z_1}{z_2} \right), \quad (2.19)$$

donde $a = \sqrt{\mathbf{h}^T \Sigma^{-1} \mathbf{h}}$ es la distancia de Mahalanobis entre $\mathbf{h}$ y el origen, y Φ denota la función de distribución de la normal estándar.

Otro modelo max-stable útil es el *proceso de Brown–Resnick* (Davis y Resnick, 1984), que se obtiene al tomar $W(\mathbf{s}) = \exp\{\varepsilon(\mathbf{s}) - \delta(\mathbf{s})\}$ en la representación (2.15), donde $\varepsilon(\mathbf{s})$ es un proceso gaussiano con incrementos estacionarios y semi-variograma:

$$\gamma(\mathbf{h}) = \frac{1}{2} \text{Var}[\varepsilon(\mathbf{s} + \mathbf{h}) - \varepsilon(\mathbf{s})] = \frac{1}{2} \mathbb{E} \left[\{\varepsilon(\mathbf{s} + \mathbf{h}) - \varepsilon(\mathbf{s})\}^2 \right],$$

tal que $\varepsilon(\mathbf{s}_0) = 0$ casi seguramente para algún $\mathbf{s}_0 \in S$. El proceso de Brown–Resnick tiene la misma función exponente V que el modelo de Smith en la ecuación (2.19), con

$$a = \sqrt{2\gamma(\mathbf{h})}.$$

En la literatura, se han propuesto otros modelos max-stables alternativos, por ejemplo el modelo de *Schlather* con conjuntos aleatorios (Schlather, 2002), el proceso *Extremal-t* (Opitz, 2013) y entre otros.

En el artículo Huser et al. (2025) se ha hecho una revisión de los procesos max-stables, haciendo énfasis en las limitaciones que presentan estos modelos, como una estructura de dependencia demasiado rígida para la mayoría de las aplicaciones ambientales. Una distribución max-stable G es aquella para la cual G^t (con $G^t(x)$ definido como $\{G(x)\}^t$) sigue siendo una distribución válida dentro de la misma familia de localización-escala para todo $t > 0$. Esto implica que la estructura de dependencia de las distribuciones max-stables es invariante ante el operador máximo; es decir, si un modelo max-stable es adecuado para los máximos anuales de una variable dada, el mismo modelo también es adecuado para caracterizar la estructura de dependencia de máximos de 10, 50 o incluso 1000 años. Esto significa que, tras la estandarización marginal, los patrones de dependencia de un evento extremo espacial no cambian con la severidad del evento, sin importar lo extremo que sea. Esta rigidez a menudo contradice los hallazgos empíricos, donde los eventos extremos son dependientes pero tienden a volverse más localizados espacialmente a medida que se vuelven más extremos (Huser y Wadsworth, 2019).

También se da que algunos de los modelos max-stables más populares se caracterizan por propiedades no físicas. Los modelos max-stables de *Schlather* y *extremal-t*, por ejemplo, son no ergódicos, lo que implica que no pueden aproximarse a una independencia total entre sitios infinitamente distanciados.

Otra barrera importante al usar procesos max-stables, es al ajustar a datos reales, donde las expresiones en forma cerrada de la verosimilitud conjunta sólo pueden obtenerse en configuraciones de baja dimensión, tal como se ve en Castruccio et al. (2016). Tanto la inferencia por máxima verosimilitud como la bayesiana requieren conocer la verosimilitud conjunta de las observaciones, lo cual es extremadamente costoso de calcular para la mayoría de los modelos max-stables. Para el modelo de *Smith* en $\mathbb{R}^2$, la función de verosimilitud puede escribirse explícitamente sólo para dimensiones $d \leq 3$ (Genton

et al., 2011). En cambio, para todos los demás procesos max-stables, la verosimilitud cerrada sólo puede obtenerse para $d \leq 2$. Esto implica que si los datos son observados en $d > 2$ ubicaciones espaciales, la verosimilitud conjunta no puede expresarse en forma cerrada. En Padoan et al. (2010) se aborda este problema mediante un enfoque basado en la verosimilitud, en el cual sustituyeron la verosimilitud conjunta no disponible por una *verosimilitud compuesta*, que se construye a partir de funciones de verosimilitud de menor dimensión (por ejemplo, verosimilitudes bivariadas). También se ha abordado a través de redes neuronales como fue el caso en Sainsbury-Dale et al. (2024).

2.5. Estadística espacial

Las funciones de covarianza describen la dependencia espacial o temporal entre dos variables aleatorias en procesos estocásticos. Sea $Y(\mathbf{s})$ un vector aleatorio o proceso estocástico definido sobre un dominio $D \subseteq \mathbb{R}^p$, entonces una función de covarianza $C(\mathbf{s}_1, \mathbf{s}_2)$ proporciona la covarianza de los valores del vector aleatorio en dos ubicaciones $\mathbf{s}_1$ y $\mathbf{s}_2$, es decir:

$$C(\mathbf{s}_1, \mathbf{s}_2) = \text{cov}\{Y(\mathbf{s}_1), Y(\mathbf{s}_2)\} = \mathbb{E}[(Y(\mathbf{s}_1) - \mathbb{E}[Y(\mathbf{s}_1)])(Y(\mathbf{s}_2) - \mathbb{E}[Y(\mathbf{s}_2)])].$$

Para que una función sea una función de covarianza *válida*, la función C debe ser no negativa definida. Es decir, para $Y(\mathbf{s})$ en D con $\mathbb{E}[Y(\mathbf{s})] < \infty$ para todo $\mathbf{s} \in D$, la función de covarianza C debe satisfacer:

$$\sum_{j=1}^d \sum_{k=1}^d c_j c_k C(\mathbf{s}_j, \mathbf{s}_k) \geq 0,$$

para todo d finito, para todas las ubicaciones $\mathbf{s}_1, \dots, \mathbf{s}_d$ y para todos los reales $c_1, \dots, c_d$.

Un proceso $Y(\mathbf{s})$ se considera *estacionario* o *débilmente estacionario* si cumple con las siguientes condiciones:

- Su media es constante en todo el dominio D , es decir, para todo $\mathbf{s} \in D$, se tiene:

$$\mathbb{E}(Y(\mathbf{s})) = \mu.$$

- La función de covarianza $C(\cdot)$ es invariante frente a traslaciones. En otras palabras, para cualesquiera dos puntos $\mathbf{s}$ y $\mathbf{s} + \mathbf{h}$ dentro del dominio D , la covarianza depende únicamente de la diferencia $\mathbf{h}$ entre estos puntos:

$$\text{cov}\{Y(\mathbf{s}), Y(\mathbf{s} + \mathbf{h})\} = C(\mathbf{h}).$$

Por otro lado, un proceso $Y(\mathbf{s})$ se dice que es *isotrópico* si la función de covarianza no depende de la dirección en la que se mide la distancia, sino solo de la magnitud de esta. Formalmente, se cumple:

$$\text{cov}\{Y(\mathbf{s}), Y(\mathbf{s} + \mathbf{h})\} = C_2(\|\mathbf{h}\|),$$

para todas las ubicaciones $\mathbf{s} \in D$ y desplazamientos $\mathbf{h} \in \mathbb{R}^p$.

En las definiciones anteriores, C_1 y C_2 son funciones de covarianza que deben ser *válidas*. Es importante notar que si un proceso es isotrópico, entonces también es estacionario.

Ahora, sea $F_Y(y_1, \dots, y_d)$ la función de distribución acumulada de un vector $Y = (Y(\mathbf{s}_1), \dots, Y(\mathbf{s}_d))^T$, y Y_h el vector desplazado $(Y(\mathbf{s}_1 + \mathbf{h}), \dots, Y(\mathbf{s}_d + \mathbf{h}))^T$. Un proceso aleatorio $Y(\mathbf{s})$ se considera *estrictamente estacionario* si la distribución acumulada de Y no cambia al desplazar los puntos de observación. Es decir, para cualquier conjunto de ubicaciones $\mathbf{s}_1, \dots, \mathbf{s}_d \in D$ y cualquier desplazamiento $\mathbf{h} \in \mathbb{R}^p$, se cumple:

$$F_Y(y_1, \dots, y_d) = F_{Y_h}(y_1, \dots, y_d).$$

Esto significa que la función de distribución de probabilidad subyacente es invariante ante traslaciones. Además, cabe destacar que un proceso gaussiano que es débilmente

estacionario también es estrictamente estacionario.

Se han propuesto diversas funciones de covarianza paramétricas y no paramétricas en la literatura, pero el enfoque paramétrico es frecuentemente preferido debido a su facilidad de modelado e interpretación. Entre las funciones de covarianza isotrópicas paramétricas, la familia de Matérn Guttorp y Gneiting (2006) ha sido ampliamente utilizada debido a su flexibilidad para modelar una gran variedad de datos espaciales con diferentes características de suavidad.

La función de covarianza, escrita como $C(\mathbf{h} \mid \nu, \rho)$, puede expresarse como:

$$C(\mathbf{h} \mid \nu, \rho) = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\sqrt{2\nu} \frac{\|\mathbf{h}\|}{\rho} \right)^\nu K_\nu \left(\sqrt{2\nu} \frac{\|\mathbf{h}\|}{\rho} \right),$$

donde $\|\mathbf{h}\|$ es la distancia espacial, σ^2 es la varianza marginal, K_ν es la función de Bessel de segunda especie de orden ν la cual se puede encontrar en Abramowitz y Stegun (1948), $\rho > 0$ es el parámetro de rango espacial y $\nu > 0$ es el parámetro de suavidad. Esta clase de funciones de covarianza es positiva definida para cualquier dimensión entera $d \geq 1$.

La función de correlación exponencial $C(\mathbf{h} \mid \rho) = \exp(-\|\mathbf{h}\|/\rho)$ y la función de correlación gaussiana $C(\mathbf{h} \mid \rho) = \exp(-(\|\mathbf{h}\|/\rho)^2)$ pueden obtenerse cuando $\nu = 0,5$ y cuando $\nu \rightarrow \infty$, respectivamente, en la expresión anterior.

2.5.1. Modelado de la dependencia espacial mediante modelos de cópulas

Los modelos geoestadísticos basados en la distribución Gaussiana son ampliamente utilizados en la estadística espacial, lo que motiva la exploración de su aplicación en el modelado de extremos espaciales. Una opción es transformar los datos a la escala Gaussiana y luego aplicar herramientas geoestadísticas. Sin embargo, al tratar con extremos, la dependencia entre las variables puede ser compleja y no siempre se captura adecuadamente. En este contexto, las cópulas ofrecen una herramienta poderosa para modelar la dependencia espacial en eventos extremos. Permiten separar la estructura

de dependencia de las distribuciones marginales, proporcionando una forma flexible y eficaz de describir las relaciones entre las variables en presencia de extremos.

Una cópula $C(\mathbf{u})$, $\mathbf{u} = (u_1, \dots, u_d)^T \in [0, 1]^d$, es una función de distribución multivariada con marginales uniformes $\text{Uniforme}(0, 1)$. En otras palabras, una cópula d -variante $C : [0, 1]^d \rightarrow [0, 1]$ es la función de distribución acumulada (CDF) de un vector aleatorio $\mathbf{U} = (U_1, \dots, U_d)^T$ con marginales fijas uniformes, es decir:

$$C(\mathbf{u}) = \Pr(U_1 \leq u_1, \dots, U_d \leq u_d),$$

donde $\Pr(U_j \leq u_j) = u_j$, para $j \in \{1, \dots, d\}$ y $0 \leq u_j \leq 1$.

Al utilizar el Teorema de Sklar, elaborado en Sklar (1959), permite que una distribución conjunta d -dimensional $F_{\mathbf{Y}}$ de cualquier vector aleatorio $\mathbf{Y} = (Y_1, \dots, Y_d)^T$ puede escribirse como:

$$F_{\mathbf{Y}}(y_1, \dots, y_d) = C(F_{Y_1}(y_1), \dots, F_{Y_d}(y_d)),$$

donde $F_{Y_1}, \dots, F_{Y_d}$ son las distribuciones marginales univariadas de $Y_1, \dots, Y_d$ y C es una cópula. Si las distribuciones marginales univariadas $F_{Y_1}, \dots, F_{Y_d}$ son absolutamente continuas, entonces la cópula C está unívocamente definida en $[0, 1]^d$ y se expresa como:

$$C(\mathbf{u}) = F_{\mathbf{Y}}\left(F_{Y_1}^{-1}(u_1), \dots, F_{Y_d}^{-1}(u_d)\right), \quad \mathbf{u} \in [0, 1]^d.$$

La densidad c de la cópula se obtiene diferenciando la CDF de la cópula, y se expresa como:

$$c(\mathbf{u}) = \frac{f_{\mathbf{Y}}\left(F_{Y_1}^{-1}(u_1), \dots, F_{Y_d}^{-1}(u_d)\right)}{f_{Y_1}\left(F_{Y_1}^{-1}(u_1)\right) \cdots f_{Y_d}\left(F_{Y_d}^{-1}(u_d)\right)}, \quad \mathbf{u} \in [0, 1]^d,$$

donde $f_{\mathbf{Y}}$ es la función de densidad del vector aleatorio $\mathbf{Y}$, y $f_{Y_1}, \dots, f_{Y_d}$ son las densidades marginales univariadas.

Un ejemplo de Cópula se da al tener $(Y_1, \dots, Y_d)$ una distribución conjunta Gaussiana con media cero y matriz de covarianza identidad ($\Sigma = I$), entonces la cópula

Gaussiana se define como:

$$C(u_1, \dots, u_d) = \Phi_{\Sigma} \left(\Phi^{-1}(u_1), \dots, \Phi^{-1}(u_d) \right),$$

donde Φ es la CDF univariada estándar normal, y Φ_{Σ} es la CDF Gaussiana multivariada con media cero y matriz de covarianza Σ . La densidad correspondiente se obtiene usando la ecuación anterior para $c(\mathbf{u})$.

Otro ejemplo es la cópula t de Student, que corresponde a la cópula de la distribución t multivariada con ν grados de libertad y matriz de dispersión Σ , y se puede definir como:

$$C(u_1, \dots, u_d) = T_{\nu, \Sigma} \left(T_{\nu}^{-1}(u_1), \dots, T_{\nu}^{-1}(u_d) \right),$$

donde T_{ν} y $T_{\nu, \Sigma}$ son las funciones de distribución marginal y conjunta de la t de Student, respectivamente. La densidad de la cópula t también se obtiene mediante la fórmula general.

Ahora, sea $\mathbf{y} = (y_1, \dots, y_d)$ una realización de un proceso multivariado cuyas distribuciones marginales siguen las leyes paramétricas $H_1(y_1; \Theta), \dots, H_d(y_d; \Theta)$, y una cópula subyacente C , que depende de un parámetro ψ . En este caso, el vector de parámetros $(\Theta^T, \psi^T)^T$ se puede estimar utilizando la función de verosimilitud derivada de la densidad conjunta, la cual se expresa a través de la cópula $C(H_1(y_1; \Theta), \dots, H_d(y_d; \Theta); \psi)$.

En el ámbito espacial, las distribuciones marginales H_i para $i = 1, \dots, d$ suelen depender de los puntos espaciales $\mathbf{s}_i$, en los cuales se observan las variables y_i . ψ describe la estructura de dependencia entre las variables y_i y y_j , en función de la distancia $\|\mathbf{s}_i - \mathbf{s}_j\|$ entre los puntos espaciales. Como ejemplo, al ajustar un modelo de cópula Gaussiana estacionaria en el contexto espacial, los elementos (i, j) de la matriz de covarianza Σ se definen mediante $\rho(\mathbf{s}_i - \mathbf{s}_j)$, donde ρ es la función de correlación elegida, como por ejemplo la Matérn.

La inferencia por verosimilitud puede realizarse de la forma usual, usando la matriz de información observada para estimar errores estándar en grandes muestras, y

utilizando criterios de información para comparar modelos competidores. Alternativamente, puede usarse inferencia bayesiana. Por ejemplo, Sang y Gelfand (2009) utilizan el MCMC para ajustar un modelo de cópula Gaussiana con función de correlación exponencial y marginales GEV, donde suponen una estructura de regresión y efectos aleatorios espaciales en el parámetro de localización, pero parámetros de escala y forma constantes espacialmente.

Se han propuesto recientemente otros modelos de cópulas avanzados especializados en el modelado de valores extremos. Ejemplos importantes incluyen las cópulas de valores extremos como las que se encuentran en Gudendorf y Segers (2010) y A. C. Davison et al. (2012), que están relacionadas con los procesos max-stables.

2.6. Redes Neuronales

Las redes neuronales artificiales (RNA) son una de las áreas más estudiadas en el campo del aprendizaje automático y, más específicamente, en el aprendizaje profundo (*deep learning*). Estas redes son modelos computacionales inspirados en la manera en que el sistema nervioso humano procesa la información. Aunque la analogía con el cerebro es limitada, el funcionamiento de las RNA se basa en una estructura de nodos interconectados, que simulan el comportamiento de las neuronas biológicas. Cada nodo, o “neurona”, realiza operaciones matemáticas simples; sin embargo, al combinarse en estructuras profundas, estas redes tienen la capacidad de representar funciones de gran complejidad.

El proceso de aprendizaje en una red neuronal se centra en ajustar los *pesos* de las conexiones entre los nodos para minimizar la diferencia entre la salida predicha y la salida deseada. El ajuste de estos pesos se realiza mediante algoritmos de optimización. Durante este proceso, cada peso es modificado en función del error de la red, de manera que la red mejora su capacidad de hacer predicciones precisas a lo largo del tiempo.

Para introducir no linealidades en el modelo y permitirle aprender patrones complejos, las redes neuronales emplean funciones de activación. Entre las más comunes

se encuentran la función sigmoide, la función *Exponential Linear Unit* (ELU), la función *Rectified Linear Unit* (ReLU) y la tangente hiperbólica (*tanh*). Estas funciones son esenciales para que la red neuronal pueda aprender representaciones complejas de los datos, y sin ellas, la red no podría modelar adecuadamente relaciones no lineales (Dubey et al., 2021).

A lo largo de los años, las redes neuronales han evolucionado desde arquitecturas simples como el perceptrón de una sola capa hasta estructuras más profundas y complejas, conocidas como *deep neural networks* (DNN). Estas últimas, compuestas por múltiples capas ocultas, han demostrado un rendimiento sobresaliente en tareas como clasificación de imágenes, traducción automática, reconocimiento de voz, y juegos de estrategia.

El avance en la capacidad de procesamiento, el desarrollo de bibliotecas de software especializadas y la disponibilidad de grandes volúmenes de datos han permitido la expansión y aplicación masiva de las RNA. Estos modelos han mostrado un rendimiento sin precedentes, redefiniendo los límites del aprendizaje automático tradicional.

2.6.1. Entrenamiento de Redes Neuronales: Descenso de Gradiente y Retropropagación

El entrenamiento de una RNA tiene como objetivo ajustar los parámetros internos del modelo (principalmente los pesos sinápticos y los sesgos) de tal manera que la red sea capaz de realizar predicciones precisas sobre datos previamente no vistos. Este proceso se formaliza como un problema de optimización, en el cual se busca minimizar una función de pérdida L , que cuantifica el error entre las salidas predichas por la red y las salidas esperadas. Para lograrlo, se emplean técnicas de optimización numérica, siendo el *descenso de gradiente* (*Gradient Descent*) el método más utilizado (Goodfellow et al., 2016).

El descenso de gradiente consiste en calcular el gradiente de la función de pérdida respecto a cada uno de los parámetros de la red y actualizar dichos parámetros en la

dirección opuesta al gradiente, con el fin de minimizar el error. Matemáticamente, este procedimiento se expresa como:

$$\theta := \theta - \eta \cdot \nabla_{\theta} L(\theta), \quad (2.20)$$

donde θ representa el conjunto de parámetros de la red, η es la tasa de aprendizaje (*learning rate*) y $\nabla_{\theta} L(\theta)$ es el gradiente de la función de pérdida respecto a los parámetros.

Este método puede aplicarse de diversas maneras dependiendo del tamaño del conjunto de datos utilizado en cada iteración: el descenso de gradiente completo (batch), el descenso de gradiente estocástico (SGD) y el descenso por mini-lotes (mini-batch) (Bottou, 2010). Cada uno presenta ventajas y desventajas en términos de precisión, velocidad de convergencia y estabilidad.

Sin embargo, el cálculo del gradiente en redes profundas no es trivial, ya que requiere conocer cómo varía el error en función de cada peso en las capas intermedias. Aquí es donde entra en juego el algoritmo de *retropropagación del error* o *backpropagation*, propuesto formalmente en Rumelhart et al. (1986).

El algoritmo de backpropagation emplea la regla de la cadena del cálculo diferencial para propagar hacia atrás, desde la capa de salida hasta la capa de entrada, los errores parciales con respecto a cada parámetro. De esta manera, se pueden calcular de forma eficiente los gradientes para todos los pesos de la red.

Este procedimiento se desarrolla en tres fases principales:

1. **Propagación hacia adelante:** Se calcula la salida de la red a partir de una entrada y se obtiene el error comparando con el valor objetivo.
2. **Cálculo del error:** Se deriva la función de pérdida con respecto a la salida y se propaga hacia atrás el error a través de la red.
3. **Actualización de parámetros:** Se actualizan los pesos utilizando el gradiente calculado y una tasa de aprendizaje.

Una de las grandes ventajas del algoritmo de retropropagación es su eficiencia computacional. Gracias a su formulación recursiva, el tiempo de cómputo crece linealmente con el número de capas, permitiendo entrenar redes profundas sin un costo computacional prohibitivo.

A lo largo de los años, el descenso de gradiente ha sido mejorado mediante diversas variantes que buscan optimizar su rendimiento y evitar problemas comunes como los mínimos locales o las mesetas del gradiente. Entre estas variantes destacan el método de momento, RMSProp, AdaGrad y Adam, este último propuesto en Kingma y Ba (2014). Estos métodos adaptativos ajustan la tasa de aprendizaje durante el entrenamiento, logrando una convergencia más estable y rápida, especialmente en redes con grandes cantidades de parámetros.

2.6.2. Capas densas

Las capas densas, también conocidas como *fully connected layers*, son un componente fundamental en muchas arquitecturas de redes neuronales. En estas capas, cada neurona está conectada a todas las neuronas de la capa anterior, lo que permite una integración completa de la información. Estas capas son especialmente útiles en las etapas finales de una red, donde se requiere combinar características extraídas para tomar decisiones, como clasificar una imagen o predecir una secuencia (Goodfellow et al., 2016).

Matemáticamente, una capa densa realiza una transformación lineal del tipo:

$$\mathbf{y} = f(\mathbf{W} \cdot \mathbf{x} + \mathbf{b}),$$

donde $\mathbf{x}$ es el vector de entrada, $\mathbf{W}$ es la matriz de pesos, $\mathbf{b}$ es el vector de sesgos, y f es una función de activación no lineal como ReLU, tanh o sigmoide. Este tipo de capas es ampliamente utilizado tanto en redes convolucionales, como en redes recurrentes, sirviendo como puente entre el procesamiento de características y la salida final.




Figura 2.1: Izquierda: Aplicación de filtros a una imagen. Derecha: Explicación de la operación convolucional.

2.6.3. Capas Convolucionales (CNN - Conv2D)

Las Redes Neuronales Convolucionales por LeCun et al. (1998) (CNN, por sus siglas en inglés) representan uno de los avances más significativos en el ámbito del aprendizaje profundo, especialmente en tareas relacionadas con datos que presentan estructuras espaciales, como las imágenes, los videos y los mapas tridimensionales. A diferencia de las redes neuronales densas tradicionales, las CNN están diseñadas para explotar explícitamente las relaciones espaciales entre los datos de entrada, logrando una mayor eficiencia y mejor desempeño en tareas de visión por computadora .

El concepto fundamental detrás de una CNN es la operación de *convolución*, mediante la cual se aplican filtros (también llamados *kernels*) a regiones locales de la entrada. Esta operación permite detectar patrones específicos como bordes, texturas o formas, que son fundamentales para la comprensión de imágenes.

Formalmente, para una entrada X y un filtro K , la operación convolucional se define como:

$$(X * K)(i, j) = \sum_m \sum_n X(i + m, j + n) \cdot K(m, n) \quad (2.21)$$

El resultado de aplicar un conjunto de filtros a la entrada produce lo que se conoce como mapas de características o *feature maps*. Cada mapa resalta una característica particular presente en la imagen. A medida que se apilan capas convolucionales, se logra capturar patrones cada vez más complejos y abstractos. Por ejemplo, en Zeiler y Fergus (2014) se menciona que las primeras capas pueden detectar bordes o esquinas, mientras que en capas más profundas pueden emerger representaciones de formas específicas o incluso de objetos completos.

Además de las capas convolucionales, las CNN suelen incorporar capas de *pooling*, como el *max pooling*, que tienen la función de reducir la dimensionalidad espacial de los mapas de características, preservando la información más relevante. Esto no solo disminuye la carga computacional, sino que también introduce una forma de invarianza ante pequeñas traslaciones o distorsiones en la entrada.

Según Krizhevsky et al. (2012), una de las características más importantes de las CNN es la compartición de pesos: un mismo filtro se aplica a diferentes regiones de la imagen, lo cual reduce significativamente la cantidad de parámetros del modelo en comparación con una red neuronal completamente conectada. Esta eficiencia en el número de parámetros permite entrenar modelos más profundos y generalizables con menor riesgo de sobreajuste.

El diseño de las CNN modernas suele incluir múltiples bloques compuestos por capas convolucionales, funciones de activación no lineales (como ReLU), capas de normalización (batch normalization) y capas de pooling. A esto se añaden, al final de la red, capas densas completamente conectadas que interpretan las características extraídas para realizar una tarea específica, como clasificación, segmentación o detección de objetos.

El uso de CNN ha revolucionado tareas como el reconocimiento de objetos, la segmentación semántica, el reconocimiento facial, la clasificación médica por imágenes

(radiografías, resonancias), el análisis de imágenes satelitales y mucho más. Uno de los hitos más reconocidos en la historia de las CNN fue el modelo AlexNet, que ganó el desafío ImageNet en 2012 con una ventaja significativa sobre otros enfoques tradicionales, marcando el inicio de la era moderna del aprendizaje profundo Krizhevsky et al. (2012).

2.6.4. Redes LSTM (Long Short-Term Memory)

Las Redes Neuronales Recurrentes (RNN, por sus siglas en inglés) fueron diseñadas específicamente para procesar datos secuenciales, como texto, audio o series temporales. A diferencia de las redes neuronales feedforward tradicionales, las RNN incorporan bucles en su arquitectura que permiten mantener un estado interno, o “memoria”, el cual se actualiza a medida que se recibe cada nuevo elemento de la secuencia. Esto les permite modelar dependencias temporales y capturar relaciones entre elementos separados por varios pasos temporales.

Sin embargo, a pesar de su capacidad teórica para aprender dependencias de largo plazo, en Bengio et al. (1994) se presentan dificultades prácticas cuando se trata de secuencias extensas. El principal problema radica en el fenómeno conocido como *desvanecimiento o explosión del gradiente* (*vanishing or exploding gradients*) durante el entrenamiento mediante retropropagación a través del tiempo. Este fenómeno impide que la red aprenda correlaciones significativas a largo plazo, ya que los gradientes se vuelven extremadamente pequeños o grandes, lo que resulta en actualizaciones inefectivas de los parámetros.

Para mitigar este problema, en Hochreiter y Schmidhuber (1997) se propuso la arquitectura LSTM (*Long Short-Term Memory*). Las redes LSTM introducen una celda de memoria diseñada específicamente para conservar información durante largos períodos de tiempo. A diferencia de las RNN tradicionales, las LSTM incorporan una estructura interna más sofisticada basada en compuertas que regulan el flujo de información hacia dentro, dentro y fuera de la celda.

En la red LSTM, los valores de entrada y salida son vectores del mismo tamaño

definidos por $X(t)$. La puerta de olvido decide qué información conservar y cuál eliminar combinando $X(t)$ con el estado oculto previo $h(t-1)$. Además, la salida se genera en función de la función sigmoide y se multiplica con el estado de celda anterior $C(t-1)$.

La puerta de entrada, determina la información que debe añadirse para generar $C(t)$. Esta generación se basa en la función sigmoide y la función tangente hiperbólica ($\tanh$), utilizando la puerta $\tanh$. La multiplicación de estas compuertas se suma al resultado de la multiplicación de la compuerta de olvido con $C(t-1)$ para generar $C(t)$.

El estado actual de la celda $C(t)$ pasa por la función de activación $\tanh$ y luego se multiplica por la salida de la función de activación sigmoide de la compuerta de salida para generar el estado oculto actual $h(t)$, que representa la salida de la red LSTM.

El resultado es una arquitectura capaz de aprender y conservar dependencias a largo plazo sin que el problema del desvanecimiento del gradiente afecte significativamente su desempeño.




Figura 2.2: Flujo de una capa LSTM

Las LSTM han demostrado ser altamente eficaces en una amplia gama de aplicaciones. En Sutskever et al. (2014) se evidencia su uso en procesamiento de lenguaje

natural, donde se utilizan en tareas como la generación de texto, análisis de sentimiento, traducción automática y reconocimiento de voz. También son ampliamente utilizadas en contextos donde los datos presentan estructuras temporales o secuenciales, como predicción de series temporales financieras, detección de eventos en videos, y monitoreo de sensores en sistemas ciberfísicos.

En implementaciones modernas, las LSTM suelen combinarse con otras arquitecturas, como las CNN, para formar redes híbridas que aprovechan las ventajas de ambas estructuras: la extracción de características espaciales de las CNN y la modelación de dependencias temporales de las LSTM.

2.7. Inferencia Amortizada

Aunque el MCMC es una técnica popular para la inferencia bayesiana, sufre de desventajas como la lenta convergencia, especialmente en modelos con grandes espacios de parámetros. Para superar estas limitaciones, las redes neuronales bayesianas han emergido como una extensión de las redes neuronales tradicionales, integrando principios bayesianos en su arquitectura. Este enfoque permite modelar la incertidumbre en los parámetros de la red, mejorando así la robustez del aprendizaje y favoreciendo una mayor capacidad de generalización. Un ejemplo destacado de esta estrategia es la metodología propuesta en Radev et al. (2023), que introduce un enfoque de inferencia bayesiana globalmente amortizada basado en redes neuronales invertibles. Esta técnica tiene la ventaja de aprender un estimador global que mapea probabilísticamente los datos observados con los parámetros del modelo, lo que la convierte en una alternativa eficiente al MCMC. Mediante simulaciones, la red neuronal entrenada establece una relación entre los datos y los parámetros, permitiendo realizar inferencias rápidas y precisas en distintos conjuntos de datos sin necesidad de reentrenar el modelo, siempre que estos datos pertenezcan a la misma familia de modelos.

En este contexto, dentro de la inferencia bayesiana, se parte de la premisa de que ya se tiene una comprensión adecuada del modelo directo, es decir, del mecanismo que

genera las observaciones a partir de una configuración de parámetros ocultos, θ . Este modelo directo puede expresarse de dos maneras: en enfoques basados en la verosimilitud, donde la función de verosimilitud $p(\mathbf{x}|\theta)$ es conocida y puede evaluarse analítica o numéricamente para cualquier par $(\mathbf{x}, \theta)$, o en enfoques libres de verosimilitud, en los que solo se necesita la capacidad de muestrear desde la verosimilitud. Estos últimos enfoques se implementan frecuentemente mediante simulaciones, que generan observaciones sintéticas a través de una función determinista g de los parámetros θ y el ruido aleatorio ξ :

$$\mathbf{x}_i \sim p(\mathbf{x}|\theta) \iff \mathbf{x}_i = g(\theta, \xi_i) \quad \text{con} \quad \xi_i \sim p(\xi). \quad (2.22)$$

En este caso, la verosimilitud $p(\mathbf{x}|\theta)$ se define implícitamente a través de la simulación g , pero no es posible calcular su valor exacto para una observación simulada $\mathbf{x}_i$. Esto presenta un desafío en la realización de inferencias estadísticas tradicionales, lo que lleva a la aparición de problemas libres de verosimilitud. Estos problemas son comunes, por ejemplo, cuando $p(\mathbf{x}|\theta)$ no está disponible de forma cerrada, o cuando el modelo directo se define mediante ecuaciones diferenciales estocásticas, simulaciones de Monte Carlo o algoritmos complejos.

En esta sección, el número de parámetros de un modelo matemático es denotado como p y el número de observaciones en un conjunto de datos como n . Se denota los datos simulados a partir del modelo matemático de interés como $\mathbf{x}_{1:n} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$, donde cada $\mathbf{x}_i$ puede representar un escalar o un vector. Los datos observados o de prueba se marcarán con un superíndice o (es decir, $\mathbf{x}_{1:n}^o$).

Los parámetros de un modelo matemático se representan como un vector $\Theta = (\Theta_1, \Theta_2, \dots, \Theta_D)$, y todos los parámetros entrenables de las redes neuronales invertibles y de resumen se denotarán como ϕ y ψ , respectivamente.

Cuando un conjunto de datos consiste en observaciones a lo largo de un período de tiempo, el número de observaciones se denotará como T .

Se supone que se tiene una función invertible $f_\phi : \mathbb{R}^D \rightarrow \mathbb{R}^D$, parametrizada por un

vector de parámetros ϕ , para la cual existe la inversa $f_\phi^{-1} : \mathbb{R}^D \rightarrow \mathbb{R}^D$. Por ahora, se considera el caso en que los datos simulados crudos $\mathbf{x}_{1:n}$ de tamaño $n = 1$ se introducen directamente en la función invertible sin utilizar una red de resumen.

El objetivo es entrenar una red neuronal invertible que aproxime la verdadera distribución posterior de la forma más precisa posible:

$$p_\phi(\Theta \mid \mathbf{x}) \approx p(\Theta \mid \mathbf{x}),$$

para todos los posibles Θ y $\mathbf{x}$. Se parametriza la aproximación posterior p_ϕ en términos de una Red Neuronal Condicional Invertible (cINN por sus siglas en inglés) f_ϕ , que implementa un flujo de normalización entre Θ y una variable latente gaussiana $\mathbf{z}$:

$$\Theta \sim p_\phi(\Theta \mid \mathbf{x}) \iff \Theta = f_\phi^{-1}(\mathbf{z}; \mathbf{x}), \quad \text{con } \mathbf{z} \sim \mathcal{N}_D(\mathbf{z} \mid 0, I).$$

En consecuencia, se debe lograr las salidas de $f_\phi^{-1}(\mathbf{z}; \mathbf{x})$ sigan la distribución posterior objetivo $p(\Theta \mid \mathbf{x})$. Por lo tanto, se busca que los parámetros de la red neuronal ϕ que minimicen la divergencia de Kullback–Leibler (KL) entre la distribución posterior verdadera y la aproximada para todos los posibles conjuntos de datos $\mathbf{x}$. Es decir, se busca los parámetros de la red neuronal $\hat{\phi}$ que maximicen la probabilidad posterior de los parámetros generadores de datos Θ dados los datos observados $\mathbf{x}$, para todo Θ y $\mathbf{x}$.

$$\begin{aligned} \hat{\phi} &= \arg \min_{\phi} \mathbb{E}_{p(\mathbf{x})} (\text{KL}(p(\Theta \mid \mathbf{x}) \parallel p_\phi(\Theta \mid \mathbf{x}))) \\ &= \arg \max_{\phi} \iint p(\mathbf{x}, \Theta) \log p_\phi(\Theta \mid \mathbf{x}) d\mathbf{x} d\Theta. \\ &= \arg \max_{\phi} \iint p(\mathbf{x}, \Theta) \left[\log p(f_\phi(\Theta; \mathbf{x})) + \log \left| \det J_{f_\phi} \right| \right] d\mathbf{x} d\Theta, \end{aligned} \quad (2.23)$$

donde se ha llegado a la Ecuación (2.22) mediante un cambio de variable y se ha abreviado $\partial f_\phi(\Theta; \mathbf{x}) / \partial \Theta$ (el Jacobiano de f_ϕ evaluado en Θ y $\mathbf{x}$) como J_{f_ϕ} .

Utilizando simulaciones del modelo directo (2.22), se puede aproximar las esperan-

zas minimizando la estimación de Monte Carlo del negativo de (2.23). Por lo tanto, para un lote de M conjuntos de datos simulados y parámetros generadores de datos $\{(\mathbf{x}^{(m)}, \boldsymbol{\Theta}^{(m)})\}_{m=1}^M$, se tiene:

$$\begin{aligned}\hat{\phi} &= \arg \min_{\phi} \frac{1}{M} \sum_{m=1}^M -\log p_{\phi}(\boldsymbol{\Theta}^{(m)} \mid \mathbf{x}^{(m)}) \\ &= \arg \min_{\phi} \frac{1}{M} \sum_{m=1}^M \left[-\log p(f_{\phi}(\boldsymbol{\Theta}^{(m)}; \mathbf{x}^{(m)})) - \log \left| \det J_{f_{\phi}}^{(m)} \right| \right]. \\ &= \arg \min_{\phi} \frac{1}{M} \sum_{m=1}^M \left(\frac{1}{2} \left\| f_{\phi}(\boldsymbol{\Theta}^{(m)}; \mathbf{x}^{(m)}) \right\|^2 - \log \left| \det J_{f_{\phi}}^{(m)} \right| \right).\end{aligned}\tag{2.24}$$

Si se toma (2.24) como una función de pérdida $\mathcal{L}(\phi)$, esta puede ser minimizada utilizando cualquier método de descenso de gradiente estocástico. El primer término de (2.24), se obtiene debido a que se ha tomado una distribución gaussiana unitaria para $\mathbf{z}$. Este representa el logaritmo negativo de $\mathcal{N}_D(\mathbf{z} \mid 0, I) \propto \exp(-\frac{1}{2}\|\mathbf{z}\|^2)$.

El segundo término controla la tasa de cambio de volumen inducida por la transformación no lineal aprendida de $\boldsymbol{\Theta}$ a $\mathbf{z}$ llevada a cabo por f_{ϕ} . Por lo tanto, minimizar (2.24) asegura que $\mathbf{z}$ siga la distribución gaussiana unitaria prescrita.

El correcto aprendizaje de la posterior aprendida puede garantizarse gracias a lo demostrado en Radev et al. (2020), asumiendo que la red es capaz de alcanzar el mínimo global de la función de pérdida (es decir, bajo convergencia perfecta).

Para poder generalizar a conjuntos de datos con un número arbitrario de observaciones, se utiliza la red de resumen h_{ψ} , que es responsable de reducir el conjunto de observaciones $\mathbf{x}_{1:n}$ de tamaño variable a un vector de tamaño fijo de estadísticos de resumen. A diferencia de otros métodos donde se eligen a priori los estadísticos de resumen para la estimación, esta red de resumen aprende los estadísticos más informativos directo de los datos. La arquitectura de las redes de resumen se toma de acuerdo al problema a resolver, donde por ejemplo se tienden a utilizar RNN o LSTM para datos con dependencia temporal o CNN para datos con dependencia espacial.

Al utilizar y entrenar una red de resumen $\tilde{\mathbf{x}} = h_\psi(\mathbf{x}_{1:n})$ junto con la cINN, la función objetivo cambia a:

$$\hat{\phi}, \hat{\psi} = \arg \max_{\phi, \psi} \mathbb{E}_{p(\mathbf{x}, \Theta, N)} (\log p_\phi(\boldsymbol{\theta} \mid h_\psi(\mathbf{x}_{1:n}))),$$

y su estimación de Monte Carlo se convierte en:

$$\hat{\phi}, \hat{\psi} = \arg \min_{\phi, \psi} \frac{1}{M} \sum_{m=1}^M \left(\frac{1}{2} \left\| f_\phi(\Theta^{(m)}; h_\psi(\mathbf{x}_{1:n}^{(m)})) \right\|^2 - \log \left| \det J_{f_\phi}^{(m)} \right| \right). \quad (2.25)$$

Para hacer que la estimación de $p(\Theta \mid \mathbf{x}_{1:n})$ sea manejable, se asume que existe un vector $\boldsymbol{\eta}$ de estadísticos suficientes que captura toda la información sobre Θ contenida en $\mathbf{x}_{1:n}$ en una manera de representación vectorial de tamaño fijo.

Dado que no se conoce $\boldsymbol{\eta}$, solo se puede establecer este requerimiento de forma indirecta, minimizando la estimación de Monte Carlo de la ecuación (2.25). La siguiente proposición establece que, bajo convergencia perfecta, las muestras generadas por una cINN siguen la distribución posterior verdadera dada por las salidas de una red de resumen. La prueba de esta proposición se puede encontrar en Radev et al. (2020).

Proposición 2.5. *Suponga que tiene una red f_ϕ que converge perfectamente y una red de resumen h_ψ también perfectamente entrenada. Suponga además que existe un vector $\boldsymbol{\eta}$ de estadísticos suficientes para $\mathbf{x}_{1:n}$. Entonces, si se muestrea independientemente $\mathbf{z} \sim p(\mathbf{z})$ y se aplica $f_\phi^{-1}(\mathbf{z}; h_\psi(\mathbf{x}_{1:n}))$ a cada $\mathbf{z}$, se obtienen muestras independientes de $p(\Theta \mid \mathbf{x}_{1:n})$.*

En resumen, las distribuciones posteriores aproximadas obtenidas mediante el método BayesFlow son correctas si las redes de resumen y las redes invertibles han convergido perfectamente. Sin embargo, en la práctica, una convergencia perfecta no es realista, y existen tres fuentes de error que pueden llevar a posteriores incorrectas.

1. El error de Monte Carlo introducido al utilizar simulaciones de $g(\theta, \xi)$ para aproximar la esperanza en la ecuación (2.25).

2. La red de resumen no puede capturar completamente la información relevante en los datos o cuando no existen estadísticas suficientes.
3. La red invertible que no transforma con precisión la verdadera distribución posterior en el espacio latente gaussiano prescrito.

Aunque se puede mitigar el error de Monte Carlo ejecutando el simulador $g(\theta, \xi)$ con mayor frecuencia, los dos últimos errores pueden ser más difíciles de detectar y aliviar de forma fundamentada.

El algoritmo 1 describe los pasos esenciales para el métodos BayesFlow. El algoritmo de retropropagación funciona calculando los gradientes de la función de pérdida con respecto a los parámetros de las redes neuronales, y luego ajustando dichos parámetros para llevar la función de pérdida a un mínimo.

Algoritmo 1 Inferencia Bayesiana Amortizada con el Método BayesFlow

- 1: **Fase de entrenamiento** (aprendizaje en línea con tamaño de lote M):
 - 2: **Repetir**
 - 3: **Para** $m = 1, \dots, M$
 - 4: Muestrear parámetros del modelo desde distribución la previa: $\Theta^{(m)} \sim p(\Theta)$
 - 5: **Para** $i = 1, \dots, n$
 - 6: Muestrear una instancia de ruido: $\xi^i \sim p(\xi)$
 - 7: Ejecutar la simulación para crear una observación sintética: $\mathbf{x}_i^{(m)} = g(\Theta^{(m)}, \xi^i)$
 - 8: **Fin Para**
 - 9: Pasar el conjunto de datos $\mathbf{x}_{1:n}^{(m)}$ por la red de resumen: $\tilde{\mathbf{x}}^{(m)} = h_\psi(\mathbf{x}_{1:n}^{(m)})$
 - 10: Pasar $(\Theta^{(m)}, \tilde{\mathbf{x}}^{(m)})$ por la red de inferencia en dirección directa: $\mathbf{z}^{(m)} = f_\phi(\Theta^{(m)}; \tilde{\mathbf{x}}^{(m)})$
 - 11: **Fin Para**
 - 12: Calcular la función de pérdida de acuerdo con (2.25) usando el lote de entrenamiento $\{(\Theta^{(m)}, \tilde{\mathbf{x}}^{(m)}, \mathbf{z}^{(m)})\}_{m=1}^M$
 - 13: Actualizar los parámetros de las redes neuronales ϕ, ψ mediante retropropagación
 - 14: **Hasta que** convergencia a $\hat{\phi}, \hat{\psi}$
 - 15:
 - 16: **Fase de inferencia** (dado un conjunto de datos observado o de prueba $\mathbf{x}_{1:n}^o$):
 - 17: Pasar el conjunto observado por la red de resumen: $\tilde{\mathbf{x}}^o = h_{\hat{\psi}}(\mathbf{x}_{1:n}^o)$
 - 18: **Para** $l = 1, \dots, L$
 - 19: Muestrear una instancia de variable latente: $\mathbf{z}^{(l)} \sim \mathcal{N}_D(0, I)$
 - 20: Pasar $(\tilde{\mathbf{x}}^o, \mathbf{z}^{(l)})$ por la red de inferencia en dirección inversa: $\Theta^{(l)} = f_{\hat{\phi}}^{-1}(\mathbf{z}^{(l)}; \tilde{\mathbf{x}}^o)$
 - 21: **Fin Para**
 - 22: Retornar $\{\Theta^{(l)}\}_{l=1}^L$ como una muestra de $p(\Theta | \mathbf{x}_{1:n}^o)$
-

3. Formulación del modelo

Se parte del modelo propuesto en Yadav et al. (2022), donde se modela la precipitación de la siguiente forma: sea $Y_t(\mathbf{s})$, $\mathbf{s} \in S \subset \mathbb{R}^2$, el proceso espacial de interés observado en los momentos $t \in \{1, \dots, n\}$ y en un conjunto finito de d ubicaciones $\mathbf{s}_1, \dots, \mathbf{s}_d \in S$ con región de estudio $S \subset \mathbb{R}^2$. Se define el vector aleatorio $\mathbf{Y}_t = (Y_{t1}, \dots, Y_{td})^T = \{Y_t(\mathbf{s}_1), \dots, Y_t(\mathbf{s}_d)\}^T$ como la réplica observada en el tiempo t . Se propone que los procesos $Y_t(\mathbf{s})$, $t = 1, \dots, n$, sean copias i.i.d del proceso $Y(\mathbf{s})$, de tal forma que:

$$Y_t(s) = \alpha(s)X_{1t}(\mathbf{s})X_{2t}(\mathbf{s})X_{3t}(\mathbf{s}),$$

para procesos no negativos e independientes $X_{1t}(\mathbf{s})$, $X_{2t}(\mathbf{s})$ y $X_{3t}(\mathbf{s})$. De manera similar,

$$\mathbf{X}_{1t} = (X_{1t1}, \dots, X_{1td})^T = \{X_{1t}(\mathbf{s}_1), \dots, X_{1t}(\mathbf{s}_d)\}^T,$$

$$\mathbf{X}_{2t} = (X_{2t1}, \dots, X_{2td})^T = \{X_{2t}(\mathbf{s}_1), \dots, X_{2t}(\mathbf{s}_d)\}^T,$$

$$\mathbf{X}_{3t} = (X_{3t1}, \dots, X_{3td})^T = \{X_{3t}(\mathbf{s}_1), \dots, X_{3t}(\mathbf{s}_d)\}^T \text{ y}$$

$$\alpha = (\alpha_1, \dots, \alpha_d)^T = \{\alpha(\mathbf{s}_1), \dots, \alpha(\mathbf{s}_d)\}^T.$$

Además, con cierta leve abuse de notación, se escribe de manera intercambiable $Y \sim F$, o $Y \sim F(\cdot)$ cuando sea más conveniente, para indicar que Y tiene función de distribución F , es decir, $\Pr(Y \leq y) = F(y)$, y de manera similar para distribuciones multivariadas.

Se supone que $X_{1t}(\mathbf{s})$ es un proceso de ruido tal que las variables $X_{1t}(\mathbf{s}_j)$ son i.i.d con función de distribución F_1 y con media uno, es decir, $\mathbb{E}(X_{1tj}) = 1$, para $j = 1, \dots, d$, $t = 1, \dots, n$. Además, se supone que $X_{2t}(\mathbf{s})$ es espacialmente constante, de modo que, casi seguramente, $X_{2t1} = \dots = X_{2td} \equiv X_{2t} \stackrel{\text{i.i.d}}{\sim} F_2$, para alguna distribución F_2 , y que $E(\mathbf{X}_{2t}) = 1$ para $t = 1, \dots, n$. Específicamente, se asume que F_1 tiene cola tipo Weibull, es decir,

$$1 - F_1(x) \sim cx^\eta \exp \left\{ - \left(\frac{x}{\lambda} \right)^\kappa \right\}, \quad \text{cuando } x \rightarrow \infty,$$

para algunos $\eta \in \mathbb{R}$, $\lambda > 0$, coeficiente Weibull $\kappa > 0$, y una constante $c > 0$, y de manera similar para F_2 con la misma estructura pero potencialmente diferentes parámetros.

Finalmente, se supone que $X_{3t}(\mathbf{s})$ es un proceso espacial no trivial tal que $X_{3t} \stackrel{\text{i.i.d}}{\sim} F_{X_3}$, donde la distribución conjunta F_{X_3} tiene una cópula subyacente C_{X_3} (es decir, una distribución multivariada con márgenes uniformes fijos) y una distribución marginal de cola regular, F_3 , con índice $-\frac{1}{\xi} < 0$, para algún $0 < \xi < 1$, y $E(X_{3tj}) = 1$, $j = 1, \dots, d$, $t = 1, \dots, n$.

Se supone que los tres términos aleatorios $X_{1t}(s)$, $X_{2t}(s)$, y $X_{3t}(s)$ son mutuamente independientes (también a través de diferentes tiempos t). En cuanto al parámetro de escala variable espacialmente $\alpha(\mathbf{s})$, se modela con covariables a través de una función de enlace logarítmica. Por lo tanto, el modelo general de mezcla de productos se define en los sitios observados como:

$$Y_t = \boldsymbol{\alpha} \mathbf{X}_{1t} \mathbf{X}_{2t} \mathbf{X}_{3t}, \quad t = 1, \dots, n. \quad (3.1)$$

donde $\boldsymbol{\alpha} = \exp(\gamma_0 + \gamma_1 \mathbf{Z}_1 + \dots + \gamma_p \mathbf{Z}_p)$ es el vector de escala, $\mathbf{Z}_1, \dots, \mathbf{Z}_d$ son covariables espaciales medidas en las d ubicaciones, $\Theta_\alpha = (\gamma_0, \gamma_1, \dots, \gamma_p)^T$ son los correspondientes coeficientes de regresión, n denota el total de réplicas de tiempo y las operaciones se realizan componente a componente.

Por construcción, la media del vector observado $\mathbf{Y}_t$ en la ecuación (3.1) es $\mathbb{E}(\mathbf{Y}_t) =$

α , y el índice marginal de cola es ξ , de acuerdo a lo visto en Yadav et al. (2022). Los tres vectores aleatorios en el modelo de producto (3.1) se diseñaron para tener roles distintos y capturar diferentes características. Específicamente, el vector aleatorio $\mathbf{X}_{1t}$ está compuesto por variables i.i.d, lo que permite capturar variaciones a pequeña escala y realizar cálculos bayesianos rápidos en caso de que se censuren observaciones no extremas. El término $\mathbf{X}_{2t}$ tiene una estructura espacial completamente dependiente, lo que contrarresta el término i.i.d $\mathbf{X}_{1t}$ en caso de que los datos tengan una fuerte dependencia espacial global. Finalmente, $\mathbf{X}_{3t}$ tiene una estructura de dependencia espacial no trivial, que es necesaria para capturar la decaída de la dependencia espacial con respecto a la distancia.

El producto que se formula en (3.1) se puede utilizar para construir un modelo con dependencia temporal, es decir, que las replicas de este modelo no sean del todo independientes. Originalmente en Yadav et al. (2022) se formula $\mathbf{X}_{1t}$ y $\mathbf{X}_{2t}$ de la siguiente forma:

$$X_{1tj} = \frac{E^{\beta_1}}{\Gamma(1 + \beta_1)}, E_{1tj} \stackrel{\text{iid}}{\sim} \text{Exp}(1); \quad j = 1, \dots, d; \quad t = 1, \dots, n; \quad \beta_1 > 0,$$

$$\mathbf{X}_{2t} = \frac{E^{\beta_2}}{\Gamma(1 + \beta_2)}, E_{2t} \stackrel{\text{i.i.d}}{\sim} \text{Exp}(1); \quad t = 1, \dots, n; \quad \beta_2 > 0,$$

Donde la función $\Gamma(x)$ se define como

$$\Gamma(x) = \int_0^\infty s^{x-1} e^{-s} ds \quad \text{para } x > 0.$$

Se proponen varias variaciones al modelo de Yadav et al. (2022), por ejemplo, modificar el término $\mathbf{X}_{2t}$ de tal forma que tenga un comportamiento autorregresivo (AR) siendo este positivo y de media 1. Para esto se define el término $\mathbf{X}_{2t}^{\text{AR}}$ de la siguiente forma:

$$\log(\mathbf{X}_{2t}^{\text{AR}}) = (1 - \phi)c + \phi \log(\mathbf{X}_{2(t-1)}^{\text{AR}}) + \varepsilon_t,$$

$$\varepsilon \sim N(0, \sigma^2),$$

donde ϕ es el parámetro que indica el grado de correlación temporal y ε_t se encarga de introducir aleatoriedad al modelo. En particular, $|\phi| < 1$ y es fácil ver que:

$$\begin{aligned} \mathbb{E}(\mathbf{X}_{2t}) &= \exp\left(c + \frac{\sigma^2}{2(1 - \phi^2)}\right) \\ \mathbb{V}(\mathbf{X}_{2t}) &= \left[\exp\left(\frac{\sigma^2}{1 - \phi^2}\right) - 1\right] \exp\left(2c + \frac{\sigma^2}{1 - \phi^2}\right). \end{aligned}$$

Por lo que para que el proceso $\mathbb{E}(\mathbf{X}_{2t}^{\text{AR}}) = 1$ se debe tomar $c = \frac{-\sigma^2}{2(1 - \phi^2)}$. Cuando $|\phi| > 1$ se le conoce como un proceso no causal (Shumway y Stoffer, 2017). Si $0 < \phi < 1$ se dice que las observaciones que están cercanas en tiempo están positivamente correlacionadas entre sí mismas, y si $-1 < \phi < 0$ los puntos de tiempo contiguos están negativamente correlacionados, pero las observaciones separadas por dos puntos de tiempo están positivamente correlacionados. Cuando $\phi = 0$ no hay correlación temporal, por lo que se tendría solamente un proceso log-normal. En particular, si $\phi \rightarrow 1$ o $\phi \rightarrow -1$, el término $\mathbf{X}_{2t}^{\text{AR}}$ se vuelve degenerado en cero.

En cuanto al vector aleatorio $\mathbf{X}_{3t}$, se define su distribución marginal F_3 como la distribución Gamma Inversa (IG) con parámetro de escala $\beta_3 - 1$ y de forma β_3 , para algún parámetro $\beta_3 > 1$, de modo que $E(X_{3tj}) = 1$. Además, cuando $\beta_3 \rightarrow 1$, el término $\mathbf{X}_{3t}$ se vuelve degenerado en 0 y no tiene efecto en la mezcla de la ecuación (3.3).

Además, sea la cópula subyacente $C_{\mathbf{X}_3}$ de $\mathbf{X}_{3t}$ la cópula Gaussiana con función de correlación exponencial $\rho(h) = \exp(-h/\rho)$, $h \geq 0$, y rango $\rho > 0$. Entonces, $\mathbf{X}_{3t}$ tiene distribución conjunta:

$$\mathbf{X}_{3t} | \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{mar}^T}, \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{dep}^T} \sim \Phi\left(\Phi^{-1}\left(\text{IG}\{.; \beta_3, \beta_3 - 1\}\right), \quad \dots, \quad \Phi^{-1}\left(\text{IG}\{.; \beta_3, \beta_3 - 1\}\right)\right),$$

donde $\Theta_{\mathbf{X}_3}^{\text{mar}^T}$ contiene los parámetros que controlan la distribución marginal y $\Theta_{\mathbf{X}_3}^{\text{dep}^T}$ controla dependencia espacial. Φ es la función de distribución de la Gaussiana multivariada con media cero y matriz de correlación $\Sigma(\rho)$ con entradas $\Sigma_{i_1, i_2} = \exp\left(\frac{-\|\mathbf{s}_{i_1} - \mathbf{s}_{i_2}\|}{\rho}\right)$, y Φ^{-1} es la función cuantílica de la distribución Gaussiana estándar.

Se propone además variaciones en las dependencias temporales, donde se busca variar los términos $\mathbf{X}_{2t}^{\text{AR}}$ y $\mathbf{X}_{1t}$ en el sentido de que sean o no espacialmente constantes, donde espacialmente constante hace referencia a: $\mathbf{X}_{2t1}^{\text{AR}} = \mathbf{X}_{2t2}^{\text{AR}} \dots = \mathbf{X}_{2td}^{\text{AR}}$ Esto se denotará con el superíndice c, $\mathbf{X}_{2t}^{\text{AR-c}}$ y similar con $\mathbf{X}_{1t}^c$.

De este modo, el producto (3.1) se reescribe:

$$\mathbf{Y}_t = \alpha \mathbf{X}_{1t} \mathbf{X}_{2t}^{\text{AR-c}} \mathbf{X}_{3t}, \quad t = 1, \dots, n. \quad (3.2)$$

Esto manteniendo la espacialidad constante de los términos de (3.1), sin embargo, se puede proponer:

$$\mathbf{Y}_t = \alpha \mathbf{X}_{1t}^c \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}, \quad t = 1, \dots, n, \quad (3.3)$$

o también suprimiendo algún término:

$$\mathbf{Y}_t = \alpha \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}, \quad t = 1, \dots, n, \quad (3.4)$$

En el capítulo 5, se presentan resultados bajo distintas combinaciones de los términos. El vector de hiperparámetros para el modelo propuesto y las respectivas combinaciones de espacialidad es:

$$\Theta = \left(\Theta_{\alpha}^T, \Theta_{\mathbf{X}_1}^T, \Theta_{\mathbf{X}_2^{\text{AR}}}^T, \Theta_{\mathbf{X}_3}^{\text{mar}^T}, \Theta_{\mathbf{X}_3}^{\text{dep}^T} \right)^T,$$

donde:

$$\Theta_{\alpha} = (\gamma_0, \gamma_1, \dots, \gamma_p)^T, \quad \Theta_{\mathbf{X}_1} = \beta_1, \quad \Theta_{\mathbf{X}_2^{\text{AR}}} = (\phi, \sigma)^T, \quad \Theta_{\mathbf{X}_3}^{\text{mar}} = \beta_3, \quad \Theta_{\mathbf{X}_3}^{\text{dep}} = \rho.$$

En particular, para la aplicación del y sus respectivas variantes, se toma $\beta_1 = 0,5$. Se fija este parámetro debido a la complejidad que implica su estimación al considerar simultáneamente la dependencia temporal y espacial en el modelo. Esta elección permite simplificar el análisis sin comprometer significativamente la capacidad descriptiva del enfoque propuesto.

Es posible considerar estructuras alternativas de cópula para $\mathbf{X}_{3t}$. Una alternativa natural, que produce dependencia asintótica en el vector de datos Y , es la cópula t de Student con matriz de dispersión $\Sigma(\gamma)$ y grados de libertad $\nu > 0$. La escogencia del log-AR(1) se basó en principalmente en su propiedad de no ser negativo, algo que es relevante cuando se trabaja con precipitación, sin embargo, en futuros trabajos se puede considerar variaciones de este término.

4. Estimación de hiperparámetros

A partir de la ecuación (3.3), se puede observar que la verosimilitud de $\mathbf{Y}$ no es conocida, por lo que siguiendo los pasos de Yadav et al. (2022), una opción es reescribir de forma jerárquica la mezcla espacial del producto de la siguiente manera:

$$\begin{aligned}
 Y_{tj} \mid \mathbf{X}_{2t}^{\text{AR}}, \mathbf{X}_{3t}, \boldsymbol{\Theta}_{\mathbf{X}_1}, \boldsymbol{\Theta}_{\boldsymbol{\alpha}} &\stackrel{\text{ind}}{\sim} F_1 \left(\cdot / (\alpha_j X_{3tj} X_{2tj}^{\text{AR}}); \boldsymbol{\Theta}_{\mathbf{X}_1} \right), \quad j = 1, \dots, d, \quad t = 1, \dots, n; \\
 \mathbf{X}_{2t}^{\text{AR}} \mid \boldsymbol{\Theta}_{\mathbf{X}_{2t}^{\text{AR}}} &\sim F_2(\cdot; \boldsymbol{\Theta}_{\mathbf{X}_2}); \\
 \mathbf{X}_{3t} \mid \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{mar}}, \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{dep}} &\stackrel{\text{ind}}{\sim} C_{\mathbf{X}_3} \left\{ F_3(\cdot; \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{mar}}), \dots, F_3(\cdot; \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{mar}}); \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{dep}} \right\}; \\
 \boldsymbol{\Theta} &\sim \pi(\boldsymbol{\Theta}),
 \end{aligned}$$

donde $\boldsymbol{\Theta} = (\boldsymbol{\Theta}_{\boldsymbol{\alpha}}^T, \boldsymbol{\Theta}_{\mathbf{X}_1}^T, \boldsymbol{\Theta}_{\mathbf{X}_{2t}^{\text{AR}}}^T, \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{mar}T}, \boldsymbol{\Theta}_{\mathbf{X}_3}^{\text{dep}T})^T$. Esta construcción jerárquica del modelo de producto propuesto (3.3) sugiere utilizar inferencia bayesiana basada en el vector completo de datos $\mathbf{Y} = (\mathbf{Y}_1^T, \dots, \mathbf{Y}_n^T)^T$, tratando a $\mathbf{X}_2^{\text{AR}} = (\mathbf{X}_{21}^{\text{AR}}, \dots, \mathbf{X}_{2n}^{\text{AR}})^T$ y $\mathbf{X}_3 = (\mathbf{X}_{31}^T, \dots, \mathbf{X}_{3n}^T)^T$ como variables latentes. Estos dos vectores latentes, $\mathbf{X}_2^{\text{AR}}$ y $\mathbf{X}_3$, son de dimensiones n y nd , respectivamente. Por lo tanto, habrá un total de $n + nd + |\boldsymbol{\Theta}|$ variables latentes e hiperparámetros para hacer inferencia simultáneamente. Sea $\pi(\cdot)$ una densidad genérica (condicional), entonces la densidad posterior conjunta de $\boldsymbol{\Theta}$, $\mathbf{X}_2^{\text{AR}}$, y $\mathbf{X}_3$, denotada por $\pi_{\text{post}}(\boldsymbol{\Theta}; \mathbf{X}_2^{\text{AR}}; \mathbf{X}_3 \mid \mathbf{Y})$, es proporcional a:

$$\pi(\mathbf{Y}; \boldsymbol{\Theta}; \mathbf{X}_2^{\text{AR}}; \mathbf{X}_3) = \pi(\mathbf{Y} \mid \mathbf{X}_2^{\text{AR}}; \mathbf{X}_3; \boldsymbol{\Theta}_{\mathbf{X}_1}) \pi(\mathbf{X}_2^{\text{AR}} \mid \boldsymbol{\Theta}_{\mathbf{X}_2^{\text{AR}}}) \pi(\mathbf{X}_3 \mid \boldsymbol{\Theta}_{\mathbf{X}_3}) \pi(\boldsymbol{\Theta}),$$

y la densidad posterior de Θ se obtiene integrando las variables latentes $\mathbf{X}_2^{\text{AR}}$ y $\mathbf{X}_3$, es decir,

$$\pi(\Theta \mid \mathbf{Y}) = \int \int \pi_{\text{post}}(\Theta; \mathbf{X}_2^{\text{AR}}; \mathbf{X}_3 \mid \mathbf{Y}) d\mathbf{X}_2^{\text{AR}} d\mathbf{X}_3. \quad (4.1)$$

La dimensión de la integral en (4.1) es muy grande. Para resolver este problema, se procede a utilizar lo visto en la sección 2.7 sobre inferencia amortizada. Para esto se propone dividir el problema en dos, en una red R_α que se encargue de estimar y generar muestras posteriores de los hiperparámetros de la componente de covariables Θ_α y una red $R_{\mathbf{X}}$ que se encarga de estimar y generar muestras posteriores de los hiperparámetros $\Theta_{\mathbf{X}_3}^{\text{mar}}$, $\Theta_{\mathbf{X}_3}^{\text{dep}}$ y $\Theta_{\mathbf{X}_2^{\text{AR}}}$.

4.1. Arquitectura de las redes

Si se denota con letras minúsculas denotando valores realizados, es decir, y_{tj} es la realización de $Y_{tj} = Y_t(\mathbf{s}_j)$, x_{2tj} es la realización de $X_{2tj}^{\text{AR}} = \mathbf{X}_{2t}^{\text{AR}}(\mathbf{s}_j)$, y así sucesivamente. Se define de forma matricial una simulación del proceso $\mathbf{Y}$ de la siguiente forma:

$$\mathbf{Y} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1d} \\ y_{21} & y_{22} & \cdots & y_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nd} \end{bmatrix}.$$

Para cada sitio se tendrá un umbral u_j , $i = 1, \dots, d$. De este modo, se define $y_{tj}^\vee = \max\{y_{tj}, u_j\}$. Este nuevo $y_{tj}^\vee$ es una versión censura de y_{tj} , donde se prioriza las excedencia sobre el umbral. De manera análoga, se define la matriz $\mathbf{Y}^\vee = \{y_{tj}^\vee\}_{t=1, j=1}^n d$, donde cada elemento $y_{tj}^\vee$ representa el valor correspondiente en la posición (t, j) de la matriz. De esta forma, en el entrenamiento e inferencia de la red R_α , recibirá de entrada varias matrices $\mathbf{Y}^\vee$, añadiendo las columnas de los hiperparámetros utilizados para la generación de cada matriz $\Theta_{\mathbf{X}_3}^{\text{mar}}$, $\Theta_{\mathbf{X}_3}^{\text{dep}}$ y $\Theta_{\mathbf{X}_2^{\text{AR}}}$, permitiendo así tener una red R_α que

infiere muestras posteriores de Θ_α condicionada a los demás hiperparámetros. En el cuadro 4.1 se presenta la arquitectura para la red de resumen de R_α , diseñada para procesar secuencias de longitud n (i.e series de tiempo) que van $t = 1, \dots, n$, donde cada elemento contiene $d + 4$ características, donde d hace referencia al número de sitios y 4 corresponde los 4 hiperparámetros de entrada, donde este valor varía de acuerdo a la cantidad de hiperparámetros. Esta red está compuesta por una serie de capas secuenciales que permiten capturar la información contextual de la entrada y generar una representación compacta y expresiva.

La red comienza con una capa de entrada que recibe tensores de tamaño $[n, d + 4]$. Luego, se aplican dos capas LSTM. La primera mantiene la serie completa y transforma cada elemento en un vector de dimensión n_{LSTM} , resultando en una salida de tamaño $[n, n_{\text{LSTM}}]$. La segunda capa LSTM reduce esta representación secuencial a un único vector, conservando solo el último estado oculto, con tamaño $[n_{\text{LSTM}}]$.

La salida de la segunda LSTM se procesa mediante dos capas densas. La primera emplea una función de activación ReLU y transforma la dimensión a $[n_{\text{Densa}}]$. La segunda, también densa, utiliza una activación ELU y mantiene la misma dimensionalidad. La elección de esta arquitectura responde a un equilibrio entre capacidad expresiva y eficiencia computacional. Se utilizaron dos capas LSTM con el objetivo de capturar dependencias temporales tanto locales como globales en la serie de entrada, sin incurrir en un sobreajuste o en un aumento significativo del tiempo de entrenamiento que podría derivarse del uso de arquitecturas más profundas, como podría ser más de dos capas LSTM, se optó por una sola capa densa con activación ReLU, seguida de una capa densa con activación ELU, las cuales estas dos últimas se definen de acuerdo a lo visto en Radev et al. (2020). En el capítulo se presenta resultados de ejercicios de simulación con variaciones en los valores de $[n_{\text{LSTM}}]$ y $[n_{\text{Densa}}]$.

Capa	Tamaño de Entrada	Tamaño de Salida
Entrada	$[n, d + 4]$	—
LSTM	$[n, d + 4]$	$[n, n_{\text{LSTM}}]$
LSTM	$[n, n_{\text{LSTM}}]$	$[n_{\text{LSTM}}]$
Densa (ReLU)	$[n_{\text{LSTM}}]$	$[n_{\text{Densa}}]$
Densa (ELU)	$[n_{\text{Densa}}]$	$[n_{\text{Densa}}]$

Cuadro 4.1: Arquitectura de la red de resumen R_α

Para el entrenamiento de la red $R_{\mathbf{X}}$, la estrategia de entrenamiento e inferencia es diferente. Se define $x_{tj} = x_{1tj}^d x_{2tj}^{\text{AR}} x_{3tj}$, es decir, la realización de y_{tj} sin la componente de covariables α_j , o otra forma de definirlo es $x_{tj} = \frac{y_{tj}}{\alpha_j}$. Así mismo, se define $x_{tj}^\vee = \frac{y_{tj}^\vee}{\alpha_j}$. La entrada para la red de resumen de $R_{\mathbf{X}}$ sería un conjunto de matrices donde cada matriz es de dimensión $d_1 \times d_2$ tal que $d_1 \cdot d_2 = d$, de modo que cada matriz es un arreglo regular de los sitios en un tiempo t , por lo que se define la matriz $\mathbf{X}_t^\vee$ de la siguiente forma:

$$\mathbf{X}_t^\vee = \begin{bmatrix} x_{t1}^\vee & x_{t2}^\vee & \cdots & x_{td_2}^\vee \\ x_{t(d_2+1)}^\vee & x_{t(d_2+2)}^\vee & \cdots & x_{t(2d_2)}^\vee \\ \vdots & \vdots & \ddots & \vdots \\ x_{t(d_1 \cdot d_2 - d_2)}^\vee & x_{t(d_1 \cdot d_2 - d_2 + 1)}^\vee & \cdots & x_{t(d_1 \cdot d_2)}^\vee \end{bmatrix}.$$

En particular, para los ejercicios de simulación se toma $d_1, d_2 = 10$ y aplicación $d_1, d_2 = 5$, sin embargo, estos parámetros son variables de acuerdo a la cantidad de sitios, pero el incremento, aumenta significativamente el costo computacional. Es importante mencionar que la matrix $\mathbf{X}_t$ es una matriz regular con los sitios en S para un tiempo t , esto representa una limitación de este trabajo al no permitir una estimación completa para dominios S irregulares, donde no necesariamente los sitios van a estar ubicados en una grilla regular. Existen soluciones para esto como las de Sainsbury-Dale et al. (2025) que considera Graph neural networks que son diseñadas para usar con datos que pueden

ser representadas como grafos, donde los nodos y las relaciones entre los nodos puede capturar las relaciones espaciales (Zhang et al., 2019), por lo que se deja el uso de este tipo de red en la metodología para para futuras investigaciones.

Capa	Tamaño de entrada	Tamaño de salida	Tamaño del Filtros	Número de Filtros
Entrada	$[n, d_1, d_2, 1]$	-	-	-
TimeDistributed Conv2D	$[n, d_1, d_2, 1]$	$[n, d_1, d_2, 32]$	3×3	32
TimeDistributed Conv2D	$[n, d_1, d_2, 32]$	$[n, d_1, d_2, 64]$	3×3	64
TimeDistributed Flatten	$[n, d_1, d_2, 64]$	$[n, d_1 \cdot d_2 \cdot 64]$	-	-
LSTM	$[n, d_1 \cdot d_2 \cdot 64]$	$[n_{\text{LSTM}}]$	-	-
LSTM	$[n, n_{\text{LSTM}}]$	$[n_{\text{LSTM}}]$	-	-
Densa (ReLU)	$[n_{\text{Densa}}]$	$[n_{\text{Densa}}]$	-	-
Densa (ELU)	$[n_{\text{Densa}}]$	$[n_{\text{Densa}}]$	-	-

Cuadro 4.2: Arquitectura para la red de resumen de $R_{\mathbf{X}}$

El cuadro 4.2 describe la arquitectura de la red de resumen $R_{\mathbf{X}}$, diseñada para procesar series de matrices $d_1 \times d_2$. Cada elemento de la serie tiene un único canal, por lo que la entrada a la red es un conjunto de matrices de tamaño $[n, d_1, d_2, 1]$, donde n representa la longitud de la serie temporal.

La red comienza con dos capas convolucionales 2D aplicadas a cada paso temporal de forma independiente mediante el wrapper TimeDistributed (TensorFlow, 2024), lo que permite preservar la estructura secuencial. La primera capa convolucional tiene 32 filtros de tamaño 3×3 , generando una salida de tamaño $[n, d_1, d_2, 32]$. Posteriormente, se aplica una segunda capa Conv2D también dentro de TimeDistributed, con 64 filtros del mismo tamaño, resultando en una salida de $[n, d_1, d_2, 64]$.

Posteriormente, los mapas de activación son transformados en vectores planos mediante una capa TimeDistributed Flatten, convirtiendo cada paso temporal en un vector de tamaño del producto de $d_1 \cdot d_2 \cdot 64$, es decir, la salida es una matriz de tamaño $[n, d_1 \cdot d_2 \cdot 64]$.

Esta secuencia vectorial se procesa mediante dos capas LSTM. La primera conser-

va la estructura temporal y transforma cada vector en una representación de tamaño n_{LSTM} , mientras que la segunda LSTM resume toda la secuencia en un único vector, de tamaño $[n_{\text{LSTM}}]$, correspondiente al último estado oculto.

Finalmente, se aplican dos capas densas: la primera con activación ReLU y la segunda con activación ELU. Ambas tienen dimensión n_{Densa} , y permiten introducir no linealidades adicionales para obtener una representación final más expresiva.

Los parámetros n_{Densa} y n_{LSTM} son variados en el capítulo 5, sin embargo, la arquitectura emplea únicamente dos capas convolucionales con una cantidad moderada de filtros (32 y 64, respectivamente) y un tamaño de kernel fijo de (3×3) . Esta decisión responde, en primer lugar, a una limitación práctica relacionada con la baja resolución de los datos de entrada (5×5) y (10×10) , donde un mayor número de capas o filtros no necesariamente incrementa la capacidad representativa del modelo, y puede incluso inducir sobreajuste. Además, el uso de kernels más grandes resultaría ineficiente y redundante dado el pequeño tamaño espacial de las entradas. En segundo lugar, experimentaciones preliminares mostraron que esta configuración básica es suficiente para capturar patrones relevantes en los datos, alcanzando un rendimiento competitivo sin requerir una arquitectura más profunda ni costosa computacionalmente. Por lo tanto, se priorizó una arquitectura ligera y efectiva, adecuada para la tarea específica y alineada con restricciones de complejidad y generalización.

4.2. Algoritmo de entrenamiento e inferencia

Tal como se describe en la sección 2.7, el método BayesFlow permite entrenar una red que utiliza simulaciones del proceso de interés generados por una previa de los hiperparámetros para obtener muestras posteriores de estos hiperparámetros. En el algoritmo 2 se presenta flujo de entrenamiento de las redes R_{α} y $R_{\mathbf{X}}$. En particular se destaca que en los pasos 8 y 20, se generan realizaciones de $y_{tj}^{\vee}$ y $x_{tj}^{\vee}$ definadas en la sección 4.1 y a su vez que para el entrenamiento de la red $R_{\mathbf{X}}$ no es necesario la generación de la previas de los hiperparámetros Θ_{α} , ya que estas no se usan para la

generación de la realización del proceso $x_{tj}^\vee$.

Una vez que se entrenan las redes, es posible generar con la red R_α muestras posteriores de Θ_α condicionado los parámetros $\Theta_{\mathbf{X}}$ y obtener muestras posteriores de $\Theta_{\mathbf{X}_3}^{\text{mar}}$, $\Theta_{\mathbf{X}_3}^{\text{dep}}$ y $\Theta_{\mathbf{X}_2^{\text{AR}}}$. El algoritmo 3 describe como a través del muestreo de Gibbs se pueden obtener muestras posteriores para el modelo (3.3) propuesto.

4.3. Evaluación del desempeño del modelo

Para evaluar el desempeño del modelo, se utilizan varias métricas. Para cada hiperparámetro Θ^{real} se puede calcular con las muestras posteriores:

- **Sesgo absoluto:** dado un parámetro Θ y un conjunto de muestras posteriores $\{\Theta^{(i)}\}_{i=1}^{n_{\text{iter}}}$, el sesgo absoluto se estima como:

$$\text{Sesgo absoluto}(\Theta) = \left| \frac{1}{n_{\text{iter}}} \sum_{i=1}^{n_{\text{iter}}} (\Theta^{(i)} - \Theta^{\text{real}}) \right|$$

- **Error estándar:** se estima como la desviación estándar de las muestras posteriores:

$$\text{Error estándar}(\Theta) = \sqrt{\frac{1}{n_{\text{iter}} - 1} \sum_{i=1}^{n_{\text{iter}}} (\Theta^{(i)} - \bar{\Theta})^2}$$

donde $\bar{\Theta} = \frac{1}{N} \sum_{i=1}^N \Theta^{(i)}$ es la media de las muestras posteriores.

- **Tamaño efectivo de muestra (ESS):** estima la cantidad de muestras independientes equivalentes en una cadena MCMC autocorrelacionada. Se calcula como:

$$\text{ESS}(\Theta) = \frac{n_{\text{iter}}}{1 + 2 \sum_{k=1}^K \rho_k}$$

donde ρ_k es la autocorrelación de orden k de la cadena de muestras de Θ , K : el mayor rezago tal que ρ_k sigue siendo significativamente distinto de cero (a menudo se corta cuando ρ_k cae por debajo de cierto umbral). A esta métrica se le divide

Algoritmo 2 Inferencia Bayesiana Amortizada con el Método BayesFlow para el modelo 3.3

- 1: n el número de observaciones del proceso.
 - 2: $\Theta = (\Theta_{\alpha}^T, \Theta_{\mathbf{X}_1}^T, \Theta_{\mathbf{X}_{2t}^{\text{AR}}}^T, \Theta_{\mathbf{X}_3}^{\text{mar}T}, \Theta_{\mathbf{X}_3}^{\text{dep}T})^T$.
 - 3: $\Theta_{\mathbf{X}} = (\Theta_{\mathbf{X}_{2t}^{\text{AR}}}^T, \Theta_{\mathbf{X}_3}^{\text{mar}T}, \Theta_{\mathbf{X}_3}^{\text{dep}T})^T$.
 - 4: **Fase de entrenamiento red R_{α}** (aprendizaje en línea con tamaño de lote M):
 - 5: **Repetir**
 - 6: **Para** $m = 1, \dots, M$
 - 7: Muestrear parámetros del modelo desde distribución la previa: $\Theta^{(m)} \sim p(\Theta)$
 - 8: Ejecutar la simulación para crear observaciones sintéticas $\mathbf{y}_{1:n}^{(m)} = \{\{y_{tj}^{\vee}\}_{t=1}^n\}_{j=1}^d\}^{(m)}$ a partir de las previas $\pi(\Theta)$
 - 9: Pasar el conjunto de datos $\mathbf{y}_{1:n}^{(m)}$ por la red de resumen: $\tilde{\mathbf{y}}^{(m)} = h_{\psi}(\mathbf{y}_{1:n}^{(m)})$
 - 10: Pasar $(\Theta_{\alpha}^{(m)}, \tilde{\mathbf{y}}^{(m)})$ por la red de inferencia en dirección directa: $\mathbf{z}^{(m)} = f_{\phi}(\Theta_{\alpha}^{(m)}; \tilde{\mathbf{y}}^{(m)})$
 - 11: **Fin Para**
 - 12: Calcular la función de pérdida de acuerdo con (2.25) usando el lote de entrenamiento $\{(\Theta_{\alpha}^{(m)}, \tilde{\mathbf{y}}^{(m)}, \mathbf{z}^{(m)})\}_{m=1}^M$
 - 13: Actualizar los parámetros de las redes neuronales ϕ, ψ mediante retropropagación
 - 14: **Hasta que** convergencia a $\hat{\phi}, \hat{\psi}$
 - 15:
 - 16: **Fase de entrenamiento red $R_{\mathbf{X}}$** (aprendizaje en línea con tamaño de lote M):
 - 17: **Repetir**
 - 18: **Para** $m = 1, \dots, M$
 - 19: Muestrear parámetros del modelo desde distribución la previa: $\Theta_{\mathbf{X}}^{(m)} \sim p(\Theta_{\mathbf{X}})$
 - 20: Ejecutar la simulación para crear observaciones sintéticas $\mathbf{x}_{1:n}^{(m)} = \{\{x_{tj}^{\vee}\}_{t=1}^n\}_{j=1}^d\}^{(m)}$ a partir de las previas $\pi(\Theta_{\mathbf{X}})$
 - 21: Pasar el conjunto de datos $\mathbf{x}_{1:n}^{(m)}$ por la red de resumen: $\tilde{\mathbf{x}}^{(m)} = h_{\psi}(\mathbf{x}_{1:n}^{(m)})$
 - 22: Pasar $(\Theta_{\mathbf{X}}^{(m)}, \tilde{\mathbf{x}}^{(m)})$ por la red de inferencia en dirección directa: $\mathbf{z}^{(m)} = f_{\phi}(\Theta_{\mathbf{X}}^{(m)}; \tilde{\mathbf{x}}^{(m)})$
 - 23: **Fin Para**
 - 24: Calcular la función de pérdida de acuerdo con (2.25) usando el lote de entrenamiento $\{(\Theta_{\mathbf{X}}^{(m)}, \tilde{\mathbf{x}}^{(m)}, \mathbf{z}^{(m)})\}_{m=1}^M$
 - 25: Actualizar los parámetros de las redes neuronales ϕ, ψ mediante retropropagación
 - 26: **Hasta que** convergencia a $\hat{\phi}, \hat{\psi}$
-

Algoritmo 3 Muestreo de Gibbs usando con inferencia amortizada

- 1: **Input:** Redes neuronales R_α , $R_{\mathbf{X}}$, número de muestras n_{iter} y realizaciones $y_{tj}^\vee$, $t = 1, \dots, n$ y $j = 1, \dots, d$
 - 2: Dar un valor inicial para $\Theta_{\mathbf{X}}^{(0)} = (\Theta_{\mathbf{X}_{2t}^{\text{AR}}}^{(0)T}, \Theta_{\mathbf{X}_3}^{\text{mar}(0)T}, \Theta_{\mathbf{X}_3}^{\text{dep}(0)T})^T$
 - 3: **Para** $i = 0$ **to** n_{iter}
 - 4: Usar la red R_α con entrada $y_{tj}^\vee$ y $\Theta_{\mathbf{X}}^{(i)}$ para obtener muestras posteriores de $\Theta_\alpha^{(i)}$
 - 5: Con la muestras posteriores $\Theta_\alpha^{(i)} = (\gamma_0^{(i)}, \gamma_1^{(i)}, \dots, \gamma_p^{(i)})^T$, calcular α_j y quitar el efecto de las covariables de la forma $x_{tj}^\vee = \frac{y_{tj}^\vee}{\alpha_j}$
 - 6: Usar la red $R_{\mathbf{X}}$ evaluada en las realizaciones $x_{tj}^\vee$ para obtener muestras posteriores de $\Theta_{\mathbf{X}}^{(i+1)}$
 - 7: **Fin Para**
 - 8: **Return:** Conjunto de muestras posteriores de $\Theta = (\Theta_\alpha^T, \Theta_{\mathbf{X}_1}^T, \Theta_{\mathbf{X}_{2t}^{\text{AR}}}^T, \Theta_{\mathbf{X}_3}^{\text{mar}T}, \Theta_{\mathbf{X}_3}^{\text{dep}T})^T$
-

por los minutos (min) para tener cuántas muestras efectivas (casi independientes) se generan por minuto de cómputo.

- **Intervalo de credibilidad (IC):** un intervalo de credibilidad ($c\%$) para el parámetro Θ se obtiene a partir de los cuantiles de la muestra posterior. Por ejemplo, para un IC del 95 %:

$$\text{IC}_{95\%} = [\Theta_{(0,025)}, \Theta_{(0,975)}],$$

donde $\Theta_{(0,025)}$ y $\Theta_{(0,975)}$ corresponden a los cuantiles 2.5 y 97.5 de las muestras.

- **Coefficiente de determinación R^2 :** se estima el parámetro Θ_i mediante la media de las muestras posteriores $\bar{\Theta}_i$, y se compara contra los valores verdaderos Θ_i^{Real} , para un conjunto de k de prueba. El coeficiente R^2 se define como:

$$R^2 = 1 - \frac{\sum_{i=1}^n (\bar{\Theta}_i - \Theta_i^{\text{Real}})^2}{\sum_{i=1}^n (\Theta_i^{\text{Real}} - \overline{\Theta^{\text{Real}}})^2}$$

donde $\bar{\Theta}_i$ es la media de las muestras posteriores para el parámetro i , y $\overline{\Theta^{\text{Real}}}$ es el promedio de los valores verdaderos.

Posteriormente, para comparar la capacidad del modelo para estimar valores extremos bajo la incertidumbre de la muestra posterior, se utilizan las siguientes métricas:

■ **Error Absoluto Cuantílico Promedio (EACP):**

$$\text{EACP} = \frac{1}{(99 - c_u) \cdot n \cdot d \cdot n_{\text{iter}}} \sum_{i=1}^{n_{\text{iter}}} \sum_{c=c_u}^{99} \sum_{t=1}^n \sum_{j=1}^d \left| q_{tj}^{(c,\text{real})} - q_{tj}^{(c,i)} \right|$$

donde $q_{tj}^{(c,\text{real})}$ es el cuantíl $c\%$ de las realizaciones reales, $q_{tj}^{(c,i)}$ es el cuantíl $c\%$ del proceso simulado con la muestra posterior $\Theta^{(i)}$, c_u índice del porcentaje por el cual a partir de este se comienza a medir el error cuantílico, n el número de replicas simuladas, d número de sitios simulados y n_{iter} el número de muestras posteriores.

■ **Error Cuadrático Cuantílico Promedio (ECCP):**

$$\text{ECCP} = \frac{1}{(99 - c_u) \cdot n \cdot d \cdot n_{\text{iter}}} \sum_{i=1}^{n_{\text{iter}}} \sum_{c=c_u}^{99} \sum_{t=1}^n \sum_{j=1}^d \left(q_{tj}^{(c,\text{real})} - q_{tj}^{(c,i)} \right)^2$$

5. Análisis experimental

Para todos los entrenamientos y simulaciones de esta sección se usa el Clúster Institucional HPC de la Universidad de Costa Rica, donde se utiliza un nodo Lenovo ThinkSystem SR670 V2 con 64 núcleos Intel Xeon Gold 6338, 1 TB de RAM y una tarjeta Nvidia A100 de 80 GB. Las condiciones de entrenamiento para todos los resultados propuestos fueron 128000 simulaciones del proceso, por lo que se usaron 128000 combinaciones de hiperparámetros para que las respectivas arquitecturas aprendieran. El tiempo de generación de estas muestras en promedio ronda a las 4 horas para cada tipo de entrada para la red $(x_{tj}^\vee \text{ y } y_{tj}^\vee)$, el entrenamiento mediante el algoritmo 2 usando la librería BayesFlow de Radev et al. (2020), tarda aproximadamente 2 horas por red. El algoritmo 3 tarda aproximadamente 1 hora con 30 minutos para generar 10000 iteraciones. Los cálculos se hicieron en el lenguaje de programación Python.

5.1. Estudio de simulación

5.1.1. Propuesta

En esta sección se analizará el rendimiento de la metodología de estimación de parámetros a través del muestreo de Gibbs del algoritmo 3 haciendo uso de las 2 redes neuronales entrenadas para la estimación de parámetros. Se procedió a simular el modelo propuesto (3.3) con $d = 100$ locaciones espaciales y $n = 200$. Las ubicaciones espaciales se generan mediante una grilla uniformemente espaciada entre $[0, 1]$ y el término latente $\mathbf{X}_{3t}$ tiene una cópula gaussiana subyacente con una función de correlación exponencial

isotrópica estacionaria $\rho(\mathbf{h}) = \exp(-\|\mathbf{h}\|/\rho)$, donde $\rho > 0$ es el parámetro de rango, establecido para este ejercicio como $\rho = 0,5$. El umbral de censura u_{tj} se fija aquí en el cuantil del 75 % por sitio, basado en las observaciones $(y_{1j}, \dots, y_{nj})^T$. La decisión del cuantil es arbitraria, por lo tanto puede ser variado considerando que al hacerlo más pequeño se podría perder capacidad de estimación en los eventos extremos y que al aumentarlo, podría no haber una muestra suficiente de valores extremos perjudicando la estimación. Para este ejercicio de simulación los parámetros se eligen como $\phi = 0,7$, $\sigma = 1$, $\beta_3 = 5$ y $\rho = 0,5$, y el parámetro de escala se modela espacialmente como:

$$\boldsymbol{\alpha} = \exp(\gamma_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + \gamma_3 Z_3),$$

donde $\exp(\gamma_0) = \gamma_1 = \gamma_2 = \gamma_3 = 1$, $\mathbf{Z}_1$ denota la coordenada x de cada sitio, $\mathbf{Z}_2$ denota la coordenada y de cada sitio, y $\mathbf{Z}_3$ es una covariable generada aleatoriamente a partir de la distribución normal estándar.

En el cuadro 5.1 se presentan las 5 arquitecturas usadas. La selección de la arquitectura de cada modelo, en términos de cantidad de unidades en la capa LSTM n_{LSTM} y número de neuronas densas n_{Densas} , fue realizada con el objetivo de evaluar el desempeño del método propuesto a lo largo de un gradiente de complejidad creciente. El Modelo 1 representa una configuración simple, con una baja cantidad de unidades y neuronas en la capa densa, lo cual permite observar el comportamiento base del modelo bajo una estructura mínima. A medida que se avanza hacia el Modelo 5, se incrementa progresivamente tanto el número de unidades como el de neuronas densas, incorporando mayor capacidad representacional y no linealidad al sistema. Esta estrategia permite comparar directamente el impacto del aumento de complejidad arquitectónica sobre la calidad de las estimaciones y la estabilidad del modelo, facilitando la identificación de un punto de equilibrio entre desempeño y complejidad computacional.

Para el entrenamiento de la red se utiliza previas no informativas de tal modo que se asume que:

- $\phi \sim \text{Uniforme}(-0,85; 0,85)$

Modelo	n_{LSTM}	n_{Densas}
1	128	128
2	1024	128
3	128	1024
4	1024	1024
5	1000	2000

Cuadro 5.1: Configuración de arquitecturas para cada modelo: cantidad de neuronas en la capa LSTM y número de redes invertibles.

- $\sigma \sim \text{Uniforme}(0,05; 3)$
- $\beta_3 \sim \text{Uniforme}(2; 15)$
- $\rho_3 \sim \text{Uniforme}(0; 2\delta)$
- $\gamma_i \sim \text{Normal}(0; 2), i = 0, 1, 2, 3$

donde δ hace referencia a máxima distancia euclidiana entre los sitios calculada con las coordenadas geográficas. La escogencia de estas previas se obtuvo mediante un proceso de experimentación, dándole prioridad a la estabilidad de la simulación del proceso, puesto que para valores cercanos 0 de σ el proceso $\mathbf{X}_2$ tiende a ser constantemente 1. También se presenta que cuando el $\phi \rightarrow 1$, $\phi \rightarrow -1$, el proceso tiende a ser constantemente 0. Similarmente, cuando $\beta_3 \rightarrow 1$ el proceso X_3 tiende a infinito. El límite superior de β_3 permite un rango superior más grande, sin embargo, para efectos de simulación se prefiere limitarlo a 15, principalmente por un tema de estabilidad en los resultados de estimación, donde al ampliar el rango de β_3 se pierde capacidad de predicción en la red para otros parámetros.

En el cuadro 5.2 se presenta una comparación detallada del desempeño de cinco modelos propuestos, evaluados mediante múltiples métricas estadísticas definidas en la sección 4.1. En términos de sesgo absoluto, el Modelo 2 presenta los valores más bajos en la mayoría de los parámetros, destacando por su mayor precisión en las estimaciones. En contraste, el Modelo 3 muestra un sesgo más elevado en parámetros como γ_0 , ϕ , σ y ρ .

Respecto al error estándar, los cinco modelos mantienen valores comparables, con pequeñas variaciones entre ellos. No obstante, se observa que los Modelos 3 y 5 tienden a presentar errores estándar más bajos en los parámetros σ , β_3 y ρ , lo que implica una mayor estabilidad en estas estimaciones.

En cuanto al tamaño del intervalo de credibilidad al 95 %, los Modelos 3 y 5 ofrecen intervalos más estrechos, especialmente en los parámetros γ_0 , σ y β_3 , lo cual es deseable en términos de precisión. Por otro lado, el Modelo 2 presenta el mayor intervalo para β_3 (6.19), lo que indica menor certidumbre sobre dicha estimación.

	Modelo	γ_0	γ_1	γ_2	γ_3	ϕ	σ	β_3	ρ
Sesgo absoluto	1	0.12	0.01	0.06	0.10	0.04	0.01	0.62	0.07
	2	0.10	0.01	0.10	0.00	0.08	0.04	0.22	0.01
	3	0.21	0.03	0.13	0.09	0.20	0.10	0.34	0.20
	4	0.17	0.01	0.10	0.14	0.09	0.06	0.36	0.02
	5	0.22	0.04	0.09	0.02	0.02	0.01	0.25	0.04
Error estándar	1	0.23	0.10	0.10	0.13	0.09	0.07	1.02	0.19
	2	0.22	0.09	0.09	0.12	0.09	0.07	1.52	0.21
	3	0.19	0.08	0.09	0.12	0.07	0.09	0.69	0.16
	4	0.22	0.08	0.09	0.13	0.09	0.09	1.22	0.20
	5	0.22	0.09	0.08	0.12	0.09	0.12	0.67	0.19
95 % Tamaño de IC	1	0.89	0.39	0.38	0.52	0.37	0.28	4.09	0.72
	2	0.87	0.36	0.37	0.45	0.34	0.31	6.19	0.77
	3	0.76	0.32	0.34	0.45	0.30	0.38	2.76	0.59
	4	0.86	0.33	0.36	0.49	0.38	0.40	4.66	0.72
	5	0.89	0.35	0.31	0.48	0.37	0.47	2.79	0.68
ESS/min	1	96	105	112	104	106	108	102	108
	2	96	100	110	111	114	114	110	110
	3	106	106	112	108	110	112	111	111
	4	105	109	111	110	110	104	107	109
	5	103	102	109	110	110	113	101	112
R²	1	0.98	0.99	0.99	0.98	0.75	0.94	0.86	0.41
	2	0.97	0.99	0.99	0.98	0.74	0.94	0.59	0.39
	3	0.97	0.99	0.99	0.98	0.80	0.95	0.54	0.35
	4	0.96	0.99	0.99	0.98	0.81	0.97	0.61	0.37
	5	0.97	0.99	0.99	0.98	0.83	0.95	0.53	0.25

Cuadro 5.2: Valores de los parámetros con identificación del modelo propuesto

El tamaño efectivo de muestra por minuto revela una eficiencia adecuada en todos

los modelos, con valores consistentemente altos que sugieren una buena convergencia de las cadenas y una baja autocorrelación en las simulaciones de muestra posterior.

Finalmente, el coeficiente de determinación (R^2), se observa un ajuste excelente en todos los modelos para los parámetros γ_0 a γ_3 (con valores cercanos a 0.99). En cuanto al parámetro ϕ , el Modelo 5 muestra el mejor ajuste ($R^2 = 0,83$), mientras que para el parámetro ρ , todos los modelos obtienen valores considerablemente menores (el más bajo es 0.25 en el Modelo 5), lo que podría indicar una dificultad sistemática en capturar adecuadamente esta variable.

En la figura 5.1 y la figura 5.2 se presenta las trazas y el histograma de las muestras posteriores para el Modelo 1 y Modelo 5. Se observa que aumentar la complejidad de la red es beneficioso para los parámetros γ_3, ϕ , ρ y β_3 , no así para las covariables $\gamma_0, \gamma_1, \gamma_2$. Se observa que la mezcla de las trazas es buena y que hay un ligero sesgo en al momento de comparar las muestras posteriores contra el parámetro real.

5.1.2. Modelo propuesto en Yadav et al. (2022)

Similar a la sección anterior, se analizará el rendimiento de la metodología de estimación de parámetros a través del muestreo de Gibbs para el modelo propuesto por Yadav et al. (2022), usando las mismas condiciones para comparar la capacidad del método propuesto ante este modelo. Los parámetros para este ejercicio se toman como $\beta_1 = 0,8$, $\beta_2 = 0,7$, $\beta_3 = 5$ (i.e $\xi = 0,2$) y $\rho = 0,5$, y el parámetro de escala se modela espacialmente como

$$\alpha = \exp \left(- (\gamma_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + \gamma_3 Z_3) \right),$$

donde $\exp(\gamma_0) = \gamma_1 = \gamma_2 = \gamma_3 = 1$, $\mathbf{Z}_1$ denota la coordenada x de cada sitio, $\mathbf{Z}_2$ denota la coordenada y de cada sitio, y $\mathbf{Z}_3$ es una covariable generada aleatoriamente a partir de la distribución normal estándar. Para el entrenamiento de estas redes se utiliza previas no informativas de tal modo que se asume que:

- $\beta_j \sim \text{Uniforme}(0,05; 1)$, $j = 1, 2$




Figura 5.1: Trazas de los hiperparámetros del estudio de simulación. Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones MCMC es de 10 mil (10 K). Las líneas verticales negras muestran los valores verdaderos.

- $\beta_3 \sim \text{Uniforme}(2; 15)$
- $\rho_3 \sim \text{Uniforme}(0; 2\delta)$
- $\gamma_i \sim \text{Normal}(0; 2), i = 0, 1, 2, 3$

Estas previas son similares a las escogidas en Yadav et al. (2022), con excepción de la de β_3 , ya que en ese estudio se utilizó una distribución gamma con parámetros de forma $\frac{1}{3}$ y de escala 100, es decir, con esta previa β_3 podría tomar valores menores que 1, los cuales indefinen las simulaciones del término $\mathbf{X}_3$.

En el cuadro 5.3 se presenta una comparación de cinco modelos crecientes en complejidad según su desempeño en cuatro métricas clave. En cuanto al sesgo absoluto, los modelos 1 y 4 logran estimaciones más cercanas a los valores reales para la mayoría de




Figura 5.2: Histograma de las muestras posteriores de los hiperparámetros en el estudio de simulación. Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones es de 10 mil (10 K). Las líneas horizontales negras muestran los valores verdaderos.

los parámetros, aunque el modelo 4 muestra un sesgo elevado en β_3 . El error estándar indica estimaciones estables para γ_0 – γ_3 y β_1 – β_2 . El tamaño del intervalo de confianza al 95 % también se acorta en los modelos 3 y 4, sugiriendo mayor precisión en las estimaciones, mientras que β_3 mantiene un intervalo amplio en todos los casos, reflejando alta incertidumbre. No obstante, el modelo 1 ofrece la mejor estimación para β_3 , al presentar un sesgo bajo (0.13). Por su parte, el modelo 5 proporciona la estimación más precisa de ρ , con el menor sesgo (0.04) y una buena estabilidad. Finalmente, los valores de ESS/min tienden a disminuir ligeramente en los modelos más complejos, como es esperable. En la figura 5.4 se aprecia una mejor convergencia para el hiperparámetro ρ en el modelo 5, lo que indica que aunque hay un leve sacrificio en los demás hiperparámetros a nivel de sesgo, se evidencia que se requiere mayor complejidad en las redes para una

	Modelo	γ_0	γ_1	γ_2	γ_3	β_1	β_2	β_3	ρ
Sesgo Absoluto	1	0.09	0.00	0.00	0.02	0.01	0.02	0.16	0.15
	2	0.12	0.06	0.01	0.11	0.01	0.00	0.20	0.12
	3	0.03	0.02	0.04	0.12	0.00	0.03	1.10	0.15
	4	0.05	0.01	0.02	0.01	0.01	0.01	0.59	0.13
	5	0.08	0.07	0.04	0.03	0.00	0.01	0.28	0.04
Error Estándar	1	0.27	0.08	0.09	0.09	0.06	0.10	1.28	0.21
	2	0.28	0.09	0.08	0.10	0.02	0.11	1.40	0.22
	3	0.22	0.07	0.08	0.08	0.02	0.08	1.44	0.21
	4	0.22	0.08	0.07	0.09	0.01	0.06	1.13	0.17
	5	0.22	0.08	0.08	0.08	0.03	0.09	1.24	0.20
95 % Tamaño de CI	1	1.07	0.33	0.34	0.36	0.09	0.41	4.92	0.75
	2	1.10	0.35	0.33	0.38	0.09	0.46	5.14	0.73
	3	0.87	0.29	0.33	0.33	0.07	0.33	5.52	0.79
	4	0.85	0.30	0.27	0.34	0.06	0.28	4.45	0.68
	5	0.87	0.29	0.31	0.31	0.11	0.35	4.88	0.72
ESS/min	1	114	112	111	113	110	115	111	114
	2	114	112	107	109	116	109	118	111
	3	117	108	107	104	108	102	103	104
	4	109	107	95	102	99	114	106	108
	5	109	111	106	111	104	110	104	106
R²	1	0.98	0.99	0.99	0.99	0.99	0.91	0.84	0.78
	2	0.98	0.99	0.99	0.99	0.99	0.92	0.85	0.77
	3	0.98	0.99	0.99	0.99	0.98	0.92	0.81	0.70
	4	0.96	0.99	0.99	0.99	0.99	0.91	0.83	0.74
	5	0.98	0.99	0.99	0.99	0.97	0.90	0.83	0.71

Cuadro 5.3: Valores de los hiperparámetros con identificación del modelo Yadav et al. (2022) utilizando el método propuesto.

mejor estimación en el modelo propuesto por Yadav et al. (2022).

En el cuadro 5.4 se presentan los resultados del método de Yadav et al. (2022) para el mismo modelo. En general, se ve que a nivel de covariables y los hiperparámetros β_1 , β_2 y ρ método propuesto es competitivo a nivel de sesgo absoluto, sin embargo, para el parámetro β_3 el método propuesto se ve superado por esta otra metodología, además, en términos de incertidumbre el método de Yadav et al. (2022) es superior. Aunque los resultado sean mejores para este método, es importante destacar que la metodología propuesta de estimación permite además capturar relaciones de dependencia temporal como las que se ven en el modelo propuesto (3.3) y además que tiene mayor margen




Figura 5.3: Trazas de todos los hiperparámetros del estudio de simulación del modelo de Yadav et al. (2022). Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones MCMC es de 10 mil (10 K). Las líneas verticales negras muestran los valores verdaderos.

de mejora al explorar nuevas arquitecturas de redes, como integración del enfoque propuesto por Zaheer et al. (2017), quienes introducen Deep Sets, un marco diseñado para aprender funciones invariantes a permutaciones sobre conjuntos. Esta propuesta resulta especialmente adecuada en contextos donde las muestras pueden considerarse i.i.d, ya que permite manejar entradas cuya estructura no depende del orden de los elementos. Se considera que la incorporación de esta técnica podría mejorar la capacidad de generalización y la flexibilidad de la metodología propuesta, por lo que su implementación constituye una interesante línea de investigación futura.




Figura 5.4: Histograma de las muestras posteriores de todos los hiperparámetros en el estudio de simulación del modelo de Yadav et al. (2022). Las dos primeras filas corresponden al Modelo 1, y las dos últimas filas corresponden al Modelo 5. Las dos cadenas (roja y azul) corresponden a dos valores iniciales diferentes. El número de iteraciones es de 10 mil (10 K). Las líneas horizontales negras muestran los valores verdaderos.

	γ_0	γ_1	γ_2	γ_3	β_1	β_2	β_3	ρ
Sesgo Absoluto	0.18	0.01	0.00	0.01	0.01	0.02	0.08	0.03
Error Estándar	0.06	0.03	0.03	0.01	0.01	0.03	0.16	0.02
95 % Tamaño de CI	0.23	0.12	0.10	0.04	0.02	0.13	0.61	0.08

Cuadro 5.4: Valores de los hiperparámetros del modelo y método de estimación Yadav et al. (2022)

5.2. Aplicación

5.2.1. Descripción de los datos

Para ilustrar la metodología y el modelo propuesto, se estudió las intensidades de precipitación de diversos puntos de la región de Guancaste en Costa Rica. Se utilizaron datos del sistema *Climate Hazards Group InfraRed Precipitation with Station data* (CHIRPS) el cual es un conjunto de datos de precipitación cuasiglobal, abarcando todas las longitudes dentro de las latitudes 50°S y 50°N. Según Funk et al. (2014), CHIRPS emplea los modelos climatológicos CHPclim, imágenes de satélites con resolución de 0.05° y datos de estaciones en sitio para crear series temporales de precipitación en cuadrículas para el análisis de tendencias y la monitorización de sequías estacionales. Los datos disponibles en CHIRPS son exhibidos en total de milímetros (mm) por intervalo de tiempo dado (días, 5-días, semanal, etc.). Para esta aplicación se toma un espacio temporal del 2015 hasta el 2022, el cual se enfocó en los meses de Setiembre a Diciembre, ya que es donde se presenta la mayor cantidad de intensidad lluviosa en la región y evitar modelar no-estacionaridades temporales complejas, de modo que se tienen $n = 976$ replicas temporales y al estudiar distintas regiones de Guanacaste se obtienen $d = 83$ sitios de observación de precipitación. La distancia más larga entre dos puntos es de 160 Km y las más cercanas entre si son entre 10,90 Km, con una distancia promedio de 57,84 Km. La proporción de ceros para los sitios de estudio rondó entre 51 % a 60 %. En la figura 5.5 se aprecia la media y la desviación estándar de precipitación por cada sitio, en particular se destaca que existe un heterogeneidad de precipitación entre los sitios y además de que se presenta un aumento o disminución de la media y desviación estándar, de acuerdo a la latitud y longitud del sitio.

En la figura 5.6 se presenta la distribución de la muestra de entrenamiento y de prueba, siendo la de entrenamiento tomada con $d = 25$ sitios y la de prueba $d = 52$ sitios. Además, para entrenamiento se toman los años 2015 al 2019 ($n = 610$), dejando como de prueba los años 2020, 2021 y 2022 ($n = 366$). Existe un desbalance significativo




Figura 5.5: Media y Desviación Estándar (DE) de la precipitación en mm para cada sitio.




Figura 5.6: Distribución de los sitios de muestra de prueba y entrenamiento. Los sitios con triángulo son los que se aprecian en la figura 5.8

entre la cantidad de sitios entre la muestra de entrenamiento y la muestra de prueba, esto se debe a la complejidad computacional que involucra ampliar la grilla de puntos de entrenamiento y también que la grilla de entrenamiento debe ser regular.

5.2.2. Modelación de precipitación usando el modelo espacio-temporal

Se ajusta modelo específico de producto espacial detallado en el capítulo 3 a los datos de precipitación en sitios de Guanacaste. Además de la propuesta inicial, se proponen los siguientes modelos para un comparativo, donde se realizan variaciones del modelo (3.3), principalmente para evaluar la necesidad de incluir los términos $\mathbf{X}_{3t}$ y $\mathbf{X}_{1t}$, así como modificaciones en las relaciones de dependencia espacial, variando que el término $\mathbf{X}_2^{\text{AR}}$ sea espacialmente constante (i.e $\mathbf{X}_{2t1}^{\text{AR}} = \mathbf{X}_{2t2}^{\text{AR}} \dots = \mathbf{X}_{2td}^{\text{AR}}$) o variable. Se denotará a los términos espacialmente constantes como $\mathbf{X}_2^{\text{AR-c}}$ y $\mathbf{X}_1^{\text{c}}$

- **D1** Modelo que solamente incluye el término autorregresivo siendo este espacialmente constante, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{2t}^{\text{AR-c}}, t = 1, \dots, n$.
- **D2** Modelo con solamente el término autorregresivo siendo este espacialmente variable, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{2t}^{\text{AR}}, t = 1, \dots, n$.
- **D3** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR-c}}$ siendo este espacialmente constante y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{2t}^{\text{AR-c}} \mathbf{X}_{3t}, t = 1, \dots, n$.
- **D4** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR}}$ siendo este espacialmente variable y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}, t = 1, \dots, n$.
- **D5** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR}}$ y $\mathbf{X}_{1t}$ siendo estos espacialmente variables y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{1t} \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}, t = 1, \dots, n$.
- **D6** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR-c}}$ espacialmente constante, $\mathbf{X}_{1t}$ y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{1t} \mathbf{X}_{2t}^{\text{AR-c}} \mathbf{X}_{3t}, t = 1, \dots, n$.

- **D7** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR-c}}$ y $\mathbf{X}_{1t}^c$ espacialmente constantes y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{1t}^c \mathbf{X}_{2t}^{\text{AR-c}} \mathbf{X}_{3t}$, $t = 1, \dots, n$.
- **D8** Modelo incluyendo el término autorregresivo $\mathbf{X}_{2t}^{\text{AR}}$ y $\mathbf{X}_{1t}^c$ espacialmente constante y el término de dependencia espacial $\mathbf{X}_{3t}$, por lo que $\mathbf{Y}_t = \alpha \mathbf{X}_{1t}^c \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}$, $t = 1, \dots, n$.
- **DY** Modelo propuesto por Yadav et al. (2022) descrito en la sección 3, donde $\mathbf{X}_{2t}^c$ es un término espacialmente constante y $\mathbf{X}_{1t}$ siendo espacialmente variable y el término de dependencia espacial $\mathbf{X}_{3t}$, así $\mathbf{Y}_t = \alpha \mathbf{X}_{1t} \mathbf{X}_{2t}^c \mathbf{X}_{3t}$, $t = 1, \dots, n$.

Modelo **D8** es el modelo que se ha discutido en detalle en la sección 3. Los modelos **D1**, **D2**, **D3** y **D4** son submodelos que se encuentran anidados en **D6** y **D8**. Los modelos **D1**, **D2**, **D3** y **D4** son variaciones de los términos $\mathbf{X}_{1t}$ y $\mathbf{X}_{2t}^{\text{AR}}$ donde se varía si es o no espacialmente constante. Además, se compara con el modelo propuesto por Yadav et al. (2022) para analizar si existe una mejora al añadir el término de dependencia temporal.

Para cada uno de los modelos, mencionados anteriormente, se consideran 7 combinaciones de covariables en el término de escala α , los cuales fueron denotados por **M1** - **M7**, resultando así en 63 posibles modelos en total. En concreto, se consideran varios modelos donde el vector de escala γ comprende covariables espaciales lineales o cuadráticas en términos de latitud ($\mathbf{Z}_1$), longitud ($\mathbf{Z}_2$) y altitud ($\mathbf{Z}_3$), donde las covariables se estandarizan para que se encuentren entre $[0, 1]$. Específicamente, se consideraron las siguientes combinaciones:

$$\begin{aligned}
\mathbf{M1} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d) \\
\mathbf{M2} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1) \\
\mathbf{M3} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2) \\
\mathbf{M4} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2 + \gamma_{\text{alt}} \mathbf{Z}_3) \\
\mathbf{M5} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2 + \gamma_{\text{alt}} \mathbf{Z}_3 + \gamma_{\text{lat}}^2 \mathbf{Z}_2^2) \\
\mathbf{M6} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2 + \gamma_{\text{alt}} \mathbf{Z}_3 + \gamma_{\text{lat}}^2 \mathbf{Z}_2^2 + \gamma_{\text{lon}}^2 \mathbf{Z}_2^2) \\
\mathbf{M7} : \quad \alpha &= \exp(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2 + \gamma_{\text{alt}} \mathbf{Z}_3 + \gamma_{\text{lat}}^2 \mathbf{Z}_2^2 + \gamma_{\text{lon}}^2 \mathbf{Z}_1^2 + \gamma_{\text{alt}}^2 \mathbf{Z}_3^2)
\end{aligned} \tag{5.1}$$

El umbral de censura para cada modelo fue tomado como el cuantil 75 % de cada sitio. Para la inferencia de los hiperparámetros, se utiliza $n_{\text{LSTM}} = 1024$ y $n_{\text{Densa}} = 128$ para los modelos **D1-D8** y sus respectivas combinaciones de covariables, y para el modelo de **DY** se utiliza $n_{\text{LSTM}} = 1000$ y $n_{\text{Densa}} = 2000$. La escogencia de estas arquitecturas se basa en lo visto en los ejercicios de simulación, donde la arquitectura 2 para **D8** y la arquitectura 5 para **DY** de esta sección tiende a tener mejores indicadores generales en la estimación. Aunque para estos sean las mejores arquitecturas, no necesariamente sean las mejores para los otros modelos, pero probar las 5 arquitecturas haría que se deban entrenar $63 \cdot 5 = 315$ combinaciones, aumentando altamente la complejidad de este trabajo de investigación.

La escogencia de las previas se mantiene, a excepción de los parámetros β_1 y β_2 cuya previa se toma en una $\text{Uniforme}(0,05; 2)$, siguiendo lo visto en Yadav et al. (2022) donde las aumentan para el ejercicio de aplicación.

En el cuadro 5.5 se presenta el EACCP y el ECCCP de acuerdo a lo definido en la sección 4.3. Se destaca que en muestra de entrenamiento y de prueba el mejor modelo a nivel de EACCP es **D4-M5** seguido de **DY-M5**. En el ECCP, en la muestra de entrenamiento el mejor modelo es **D4-M5** y en la muestra de prueba es el **D8-M4** seguido de **D4-M5**. Se destaca que la magnitud del error entre la muestra de prueba y entrenamiento del EACCP se mantiene similar.

		M1	M2	M3	M4	M5	M6	M7
EACCP entren.	D1	5.499	4.904	6.085	5.441	4.632	4.672	8.625
	D2	10.640	8.228	8.766	8.369	8.296	8.682	8.511
	D3	7.334	5.129	4.975	5.681	5.085	5.920	4.984
	D4	8.133	6.322	3.867	3.659	3.150	4.104	3.997
	D5	9.687	8.262	4.130	4.121	3.563	4.113	4.137
	D6	8.221	6.341	4.364	4.559	4.438	3.892	4.876
	D7	6.350	4.601	4.687	4.999	4.081	5.148	5.705
	D8	7.716	5.990	3.756	3.451	3.206	3.804	4.040
	DY	9.819	6.375	4.389	3.858	3.189	3.742	4.808
EACCP prueba	D1	6.897	6.479	7.679	6.523	5.345	5.567	9.839
	D2	12.649	10.150	10.587	8.991	9.048	9.287	9.870
	D3	9.468	7.006	6.615	7.250	6.939	8.780	75.695
	D4	10.180	8.099	6.376	5.063	4.719	5.431	45.264
	D5	11.725	10.220	6.252	5.535	5.338	5.873	38.634
	D6	10.276	8.322	6.062	5.889	5.657	5.888	91.876
	D7	8.440	6.370	5.997	6.082	5.509	6.035	59.678
	D8	9.749	7.863	6.016	4.823	5.128	5.264	78.180
	DY	11.869	8.306	6.299	5.200	5.080	5.423	59.682
ECCCP entren.	D1	112.557	68.384	10652.915	336.499	44.003	44.682	414.385
	D2	177.312	133.659	152.654	141.856	144.704	156.077	205.547
	D3	89.494	55.599	65.627	94.351	81.976	114.847	67.256
	D4	101.487	63.928	33.038	31.731	28.973	36.610	40.577
	D5	155.813	120.412	39.145	39.201	33.210	37.388	46.544
	D6	109.488	74.898	43.442	50.467	42.769	37.642	51.600
	D7	64.909	44.228	63.245	55.807	39.782	51.931	58.939
	D8	96.907	61.945	31.652	31.230	35.962	32.512	42.471
	DY	162.304	81.407	45.012	40.455	30.536	33.988	53.180
ECCCP prueba	D1	162.986	121.387	10834.363	1256.860	78.500	79.854	292.389
	D2	291.004	232.538	253.624	216.476	208.934	216.181	401.894
	D3	177.721	115.473	110.437	161.368	149.288	251.766	9.80×10^7
	D4	191.318	132.285	94.196	78.401	70.184	79.345	1.64×10^7
	D5	264.245	215.548	98.381	83.272	77.565	88.502	9.43×10^6
	D6	205.347	153.852	94.735	91.270	82.238	88.254	6.19×10^8
	D7	142.992	97.771	98.303	98.542	86.834	90.704	4.02×10^7
	D8	185.916	132.205	88.325	69.361	89.552	73.590	2.06×10^8
	DY	269.325	157.340	102.371	76.704	72.352	77.597	5.30×10^8

Cuadro 5.5: Error absoluto cuantílico media (EACCP) y Error cuadrático cuantílico media (ECCCP) en muestras de entrenamiento (entren.) y prueba. Valores más pequeños para ambas métricas indica mejor rendimiento, y el mejor modelo para cada criterio está en color azul.




Figura 5.7: Error absoluto cuantílico medio (EACCP) de precipitación en mm por locación utilizando los años 2020, 2021 y 2022 para varios combinaciones de modelo.

En la figura 5.7 se presenta el EACCP para todas las locaciones tanto de entrenamiento y de prueba, pero manteniendo el período de prueba de 2020, 2021 y 2022. Los errores son muy uniformes, salvo para leve parte de la región sur y dos sitios en la región este de Guanacaste. En particular, en estos dos lugares es donde se tiene una de las mayores altitudes de la muestra y además de que todos las combinaciones mostradas en

esta figura tiene la covariable altitud, por lo que podría ocurrir que para estos 2 puntos al no haber muchos sitios con tanta altitud, no se pueda generalizar el proceso. Esto es posible de solucionar al incluir más sitios en la muestra de entrenamiento que tengan mayor variabilidad de altitudes.




Figura 5.8: Gráficos cuantil-cuantil de los sitios con forma triángulo en la figura 5.6 donde los cuantiles ajustados son simulados a partir del modelo **D4-M5**, donde los hiperparámetros del modelo se estiman utilizando la media posterior correspondiente y los extremos de las franjas de color son los intervalos de credibilidad al 2.5% y 97.5%

En la figura 5.8 se presenta los gráficos cuantil-cuantil para las locaciones de prueba con la forma de triángulo en la figura 5.6, pero manteniendo el período de prueba de 2020, 2021 y 2022. Esta muestra que el desempeño predictivo marginal de el modelo **D4** con la combinación de covariables **M5** es satisfactorio. Por lo tanto, se selecciona el modelo **D4** con la combinación de covariables **M5** como el mejor modelo, ya que ofrece los mejores diagnósticos de ajuste fuera de muestra y puede capturar adecuadamente las complejas dinámicas de variación espacial de los extremos de precipitación, además de que incorpora la dependencia temporal que existe a través del tiempo en cada locación.

El cuadro 5.6 muestra los estadísticos resumen posteriores para el mejor modelo **D4** con la combinación de covariables **M5**. Las estimaciones de los coeficientes de las covariables, indican que solamente la altitud es significativa ($\hat{\gamma}_{\text{alt}} = 0,01$). La estimación de ϕ es cercana a 0,6, lo que confirma que existe una fuerte dependencia temporal en los datos y que el término $\mathbf{X}_{2t}^{\text{AR}}$ es fundamental. La estimación de σ es aproximadamente 0.13, lo que indica que también hay una variabilidad temporal a pequeña escala no despreciable.

	γ_0	γ_{lon}	γ_{lat}	γ_{alt}	γ_{lon^2}	ϕ	σ	β_3	ρ
Media posterior	1.54	0.77	-0.14	0.25	0.82	0.60	0.13	2.08	1.67
Desviación estándar	1.19	1.20	0.10	0.13	1.19	0.25	0.04	0.09	0.29
Límite inferior 95 % IC	-0.82	-1.47	-0.34	0.01	-1.37	-0.09	0.04	2.00	1.17
Límite superior 95 % IC	3.73	3.18	0.06	0.51	3.19	0.88	0.20	2.32	2.32
ESS/min	107	98	99	105	108	101	109	116	114

Cuadro 5.6: Estadísticos de resumen posteriores para el modelo **D4-M5**

Finalmente, en la figura 5.9 se presentan los niveles de retorno para la región de Guanacaste en distintos períodos, estimados utilizando el modelo más preciso. Los niveles de retorno son una herramienta clave en la estadística de eventos extremos, ya que permiten prever la magnitud y la frecuencia de fenómenos poco frecuentes. Esta




Figura 5.9: Niveles de retorno de precipitación en mm a distintos años utilizando el modelo **D4-M5**.

visualización pone de manifiesto la aplicabilidad práctica de esta investigación en la gestión de riesgos ambientales y el desarrollo de estrategias de adaptación ante eventos climáticos extremos. A través de la estimación espacial de cuantiles extremos, se pueden identificar áreas más vulnerables y planificar de manera más efectiva las intervenciones necesarias.

6. Conclusiones

En este trabajo se desarrolló un modelo bayesiano de extremos espacio-temporales con el objetivo de integrar covariables relevantes para la estimación de eventos extremos en los datos de precipitación del sistema CHIRPS, en Costa Rica en los períodos 2015 y 2022.

El uso de modelos bayesianos permitió incorporar la incertidumbre de manera explícita en las predicciones, lo cual resulta esencial cuando se abordan eventos de baja probabilidad pero de alto impacto, como son los eventos extremos en el ámbito climático. El modelo con mejor de estimación de error:

$$\mathbf{Y}_t = \boldsymbol{\alpha} \mathbf{X}_{2t}^{\text{AR}} \mathbf{X}_{3t}, \boldsymbol{\alpha} = \exp \left(\gamma_0 \mathbf{1}_d + \gamma_{\text{lat}} \mathbf{Z}_1 + \gamma_{\text{lon}} \mathbf{Z}_2 + \gamma_{\text{alt}} \mathbf{Z}_3 + \gamma_{\text{lat}}^2 \mathbf{Z}_2^2 \right),$$

permite una representación más precisa de los patrones espaciales y temporales que subyacen en los fenómenos extremos, un aspecto crucial para la correcta estimación de riesgos en fenómenos meteorológicos extremos como lluvias intensas y además de ser muy innovador en contraste con recientes investigaciones que el enfoque es específicamente a la parte espacial. Además, al integrar covariables en el modelo, se logró una mayor capacidad predictiva y una comprensión más profunda de los factores que influyen en la ocurrencia y magnitud de eventos extremos.

Se ha diseñado un algoritmo de Gibbs basado en redes bayesianas para ajustar el modelo de manera eficiente en dimensiones espacio-temporales altas, donde la dimensión del vector de parámetros latentes es comparable a la dimensión de los datos. Al utilizar el algoritmo basado en redes, se evita el costoso cálculo de la verosimilitud

censurada completa, por lo que la inferencia es significativamente más rápida con altas dimensiones de datos que un método MCMC usual. Gracias a este algoritmo y las respectivas redes entrenadas, se permite ajustar modelos bayesianos complejos con una fuerte dependencia de cola a nivel de datos para los excedentes de umbral en dimensiones altas y además de la captura de la dependencia temporal mediante el término autorregresivo.

Este trabajo presenta limitaciones al momento de estimación de los parámetros, principalmente al haber reducido la previa de β_3 por una previa un poco más informativa, así como haber tomado el parámetro β_1 fijo para el comparativo de resultados. Sin embargo, dada la flexibilidad que ofrecen las redes neuronales bayesianas, es posible que al aumentar la complejidad de las arquitecturas, llegar a tener mayor alcance a los resultados. Esto aplica también para el sesgo encontrado en los modelos, donde tal vez si se amplía la cantidad de capas o filtros de la capa Conv2d, se puedan llegar a tener mejores resultados.

Se demuestra que es posible construir una red para un nivel de censura arbitrario especificado por el usuario. Sin embargo, dado que se toma el umbral de censura como una función de una única probabilidad, el marco propuesto no cubre censura específica de sitios o aleatoria que pueda surgir. La estimación bajo esquemas generales de censura especificados por el usuario es una consideración futura. También se tiene la restricción de que S es una cuadrícula regular con dimensiones fijas. Para aumentar la generalidad de la metodología, esta restricción debe ser eliminada, ya que implica que, para nuevos datos observados sobre un dominio S diferente, se debe volver a entrenar un estimador completamente nuevo desde cero. Sainsbury-Dale et al. (2025) aprovechan las Graph neural networks para construir arquitecturas que se pueden aplicar a datos irregulares y que no están atadas a un número específico d o una configuración específica de ubicaciones espaciales. La combinación de estos estimadores con el modelo propuesto se deja para futuras investigaciones.

Bibliografía

- Abramowitz, M., & Stegun, I. A. (1948). *Handbook of Mathematical Functions with Formulas, Graphs, and Mathematical Tables* (Vol. 55). US Government Printing Office.
- Alfaro-Córdoba, M., Mora-Sandí, N. P., Hidalgo, H. G., & Alfaro, E. J. (2024). Central American climate extreme trends: A statistical analysis of CLIMDEX indices. *International Journal of Climatology*, 44(11), 4115-4126. <https://doi.org/https://doi.org/10.1002/joc.8571>
- Bengio, Y., Simard, P., & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2), 157-166.
- Bottou, L. (2010). Large-Scale Machine Learning with Stochastic Gradient Descent. *Proceedings of COMPSTAT'2010*, 177-186.
- Bücher, A., & Zhou, C. (2021). A horse race between the block maxima method and the peak-over-threshold approach. *Statistical Science*, 36(3), 360-378.
- Bülte, C., Leimenstoll, L., & Schienle, M. (2024). Estimation of spatio-temporal extremes via generative neural networks. *arXiv preprint arXiv:2407.08668*.
- Casella, G., & George, E. I. (1992). Explaining the Gibbs sampler. *The American Statistician*, 46(3), 167-174. <https://doi.org/10.1080/00031305.1992.10475878>
- Castro-Camilo, D., Huser, R., & Rue, H. (2019). A spliced gamma-generalized Pareto model for short-term extreme wind speed probabilistic forecasting. *Journal of Agricultural, Biological and Environmental Statistics*, 24(3), 517-534.
- Castruccio, S., Huser, R., & Genton, M. G. (2016). High-order composite likelihood inference for max-stable distributions and processes. *Journal of Computational and Graphical Statistics*, 25(4), 1212-1229.
- Coles, S. (2001). *An Introduction to Statistical Modeling of Extreme Values*. Springer.
- Cooley, D., Cisewski, J., Erhardt, R. J., Mannshardt, E., Jeon, S., Oguna Omolo, B., & Sun, Y. (2012). A Survey of Spatial Extremes : Measuring Spatial Dependence

- and Modeling Spatial Effects. *REVSTAT-Statistical Journal*, 10(1), 135-165. <https://doi.org/10.57805/revstat.v10i1.114>
- Cooley, D., Nychka, D., & Naveau, P. (2007). Bayesian spatial modeling of extreme precipitation return levels. *Journal of the American Statistical Association*, 102(479), 824-840.
- Davis, R., & Resnick, S. (1984). Tail estimates motivated by extreme value theory. *The Annals of Statistics*, 1467-1487.
- Davison, A., & Huser, R. (2015). Statistics of Extremes. *Annual Review of Statistics and Its Application*, 2(Volume 2, 2015), 203-235. <https://doi.org/https://doi.org/10.1146/annurev-statistics-010814-020133>
- Davison, A., Huser, R., & Thibaud, E. (2019). Spatial extremes. En A. E. Gelfand, M. Fuentes, J. A. Hoeting & R. L. Smith (Eds.), *Handbook of Environmental and Ecological Statistics*. CRC Press.
- Davison, A., & Smith, R. L. (1990). Models for exceedances over high thresholds (with discussion). *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 52(3), 393-442.
- Davison, A. C., Padoan, S. A., & Ribatet, M. (2012). Statistical modeling of spatial extremes. *Statistical Science*, 27(2), 161-186.
- de Fondeville, R., & Davison, A. C. (2018). High-dimensional peaks-over-threshold inference. *Biometrika*, 105(3), 575-592. <https://doi.org/10.1093/biomet/asy026>
- de Haan, L. (1984). A spectral representation for max-stable processes. *The Annals of Probability*, 12(4), 1194-1204.
- Dubey, S. R., Singh, S. K., & Chaudhuri, B. B. (2021). Activation Functions in Deep Learning: A Comprehensive Survey and Benchmark. *arXiv preprint arXiv:2109.14545*. <https://arxiv.org/abs/2109.14545>
- Ferreira, A., & de Haan, L. (2014). The generalized Pareto process; with a view towards application and simulation. *Bernoulli*, 20(4), 1717-1737. <https://doi.org/10.3150/13-BEJ538>

- Fisher, R. A., & Tippett, L. H. C. (1928). Limiting forms of the frequency distribution of the largest or smallest member of a sample. *Mathematical Proceedings of the Cambridge Philosophical Society*, 24(2), 180-190. <https://doi.org/10.1017/S0305004100015681>
- Funk, C. C., Peterson, P. J., Landsfeld, M. F., Pedreros, D. H., Verdin, J. P., Rowland, J. D., Romero, B. E., Husak, G. J., Michaelsen, J. C., & Verdin, A. P. (2014). A quasi-global precipitation time series for drought monitoring. *U.S. Geological Survey Data*, 832(4). <http://pubs.usgs.gov/ds/832/>
- Genton, M. G., Ma, Y., & Sang, H. (2011). On the likelihood function of Gaussian max-stable processes. *Biometrika*, 98(3), 481-488. <https://doi.org/10.1093/biomet/asr020>
- Gnedenko, B. (1943). Sur La Distribution Limite Du Terme Maximum D'Une Série Aléatoire. *Annals of Mathematics*, 44(3), 423-453. Consultado el 21 de abril de 2025, desde <http://www.jstor.org/stable/1968974>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning* [<http://www.deeplearningbook.org>]. MIT Press.
- Gudendorf, G., & Segers, J. (2010). Extreme-value copulas. En *Copula Theory and its Applications* (pp. 127-145). Springer.
- Guillén-Oviedo, H. S., Cid-Serrano, L. R., & Alfaro-Martínez, E. J. (2020). Comparação de parâmetros da distribuição de valores extremos generalizada associada a eventos extremos de precipitação na América Central. *Uniciencia*, 34(1), 111-128.
- Gumbel, E. J. (1958). *Statistics of Extremes*. Columbia University Press.
- Guttorp, P., & Gneiting, T. (2006). Studies in the history of probability and statistics XLIX: On the Matern correlation family. *Biometrika*, 93(4), 989-995.
- Hastings, W. K. (1970). Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1), 97-109. <https://doi.org/10.1093/biomet/57.1.97>
- Hazra, A., Huser, R., & Jóhannesson, Á. V. (2023). Bayesian latent Gaussian models for high-dimensional spatial extremes. En *Statistical Modeling Using Bayesian*

- Latent Gaussian Models: With Applications in Geophysics and Environmental Sciences* (pp. 219-251). Springer.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- Huser, R., Opitz, T., & Thibaud, É. (2017). Bridging Asymptotic Independence and Dependence in Spatial Extremes Using Gaussian Scale Mixtures. *Spatial Statistics*, 21, 166-186. <https://doi.org/10.1016/j.spasta.2017.06.004>
- Huser, R., Opitz, T., & Wadsworth, J. L. (2025). Modeling of spatial extremes in environmental data science: time to move away from max-stable processes. *Environmental Data Science*, 4, e3. <https://doi.org/10.1017/eds.2024.54>
- Huser, R., & Wadsworth, J. L. (2019). Modeling Spatial Processes with Unknown Extremal Dependence Class. *Journal of the American Statistical Association*, 114(525), 434-444. <https://doi.org/10.1080/01621459.2017.1411813>
- Kingma, D. P., & Ba, J. (2014). Adam: A Method for Stochastic Optimization. *arXiv preprint arXiv:1412.6980*. <https://arxiv.org/abs/1412.6980>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25, 1097-1105.
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.
- Ledbetter, M., Lindgren, G., & Rootzén, H. (1983). *Extremes and Related Properties of Random Sequences and Series*. Springer.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., & Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6), 1087-1092. <https://doi.org/10.1063/1.1699114>
- Opitz, T. (2013). Extremal t processes: Elliptical domain of attraction and a spectral representation. *Journal of Multivariate Analysis*, 122, 409-413.

- Opitz, T., Huser, R., Bakka, H., & Rue, H. (2018). INLA goes extreme: Bayesian tail regression for the estimation of high spatio-temporal quantiles. *Extremes*, 21(3), 441-462.
- Pachauri, R. K., Allen, M. R., Barros, V. R., Broome, J., Cramer, W., Christ, R., Church, J. A., Clarke, L., Dahe, Q., Dasgupta, P., et al. (2014). *Climate change 2014: synthesis report. Contribution of Working Groups I, II and III to the fifth assessment report of the Intergovernmental Panel on Climate Change*. Ipcc.
- Padoan, S. A., Ribatet, M., & Sisson, S. A. (2010). Likelihood-based inference for max-stable processes. *Journal of the American Statistical Association*, 105(489), 263-277.
- Pickands III, J., et al. (1975). Statistical inference using extreme order statistics. *The Annals of Statistics*, 3(1), 119-131.
- Prescott, P., & Walden, A. (1980). Maximum likelihood estimation of the parameters of the generalized extreme-value distribution. *Biometrika*, 67(3), 723-724.
- Radev, S. T., Mertens, U. K., Voss, A., Ardizzone, L., & Köthe, U. (2020). Bayes-Flow: Learning complex stochastic models with invertible neural networks. *IEEE transactions on neural networks and learning systems*, 33(4), 1452-1466.
- Radev, S. T., Schmitt, M., Schumacher, L., Else Müller, L., Pratz, V., Schälte, Y., Köthe, U., & Bürkner, P.-C. (2023). BayesFlow: Amortized Bayesian Workflows With Neural Networks. <https://arxiv.org/abs/2306.16015>
- Reiss, R., & Thomas, M. (2007). *Statistical Analysis of Extreme Values: With Applications to Insurance, Finance, Hydrology and Other Fields*. Springer Basel AG.
- Richards, J., Sainsbury-Dale, M., Zammit-Mangion, A., & Huser, R. (2023). Likelihood-free neural Bayes estimators for censored peaks-over-threshold models. *arXiv preprint arXiv:2306.15642*.
- Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.

- Sainsbury-Dale, M., Zammit-Mangion, A., & Huser, R. (2024). Likelihood-free parameter estimation with neural Bayes estimators. *The American Statistician*, 78(1), 1-14.
- Sainsbury-Dale, M., Zammit-Mangion, A., Richards, J., & and, R. H. (2025). Neural Bayes Estimators for Irregular Spatial Data Using Graph Neural Networks. *Journal of Computational and Graphical Statistics*, 0(0), 1-16. <https://doi.org/10.1080/10618600.2024.2433671>
- Sang, H., & Gelfand, A. E. (2009). Hierarchical modeling for extreme values observed over space and time. *Environmental and ecological statistics*, 16(3), 407-426.
- Schlather, M. (2002). Models for stationary max-stable random fields. *Extremes*, 5(1), 33-44.
- Shumway, R. B., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications: With R Examples* (3rd). Springer. <https://link.springer.com/book/10.1007/978-3-319-52451-0>
- Sklar, M. (1959). Fonctions de repartition an dimensions et leurs marges. *Publ. Inst. Statist. Univ. Paris*, 8, 229-231.
- Smith, R. L. (1985). Maximum likelihood estimation in a class of nonregular cases. *Biometrika*, 72(1), 67-90.
- Smith, R. L. (1990). *Max-stable processes and spatial extremes* [Unpublished manuscript, 205].
- Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27, 3104-3112.
- TensorFlow. (2024). TimeDistributed layer [Accedido: 2025-04-25]. https://www.tensorflow.org/api_docs/python/tf/keras/layers/TimeDistributed
- Turkman, K. F., Amaral Turkman, M., & Pereira, J. (2010). Asymptotic models and inference for extremes of spatio-temporal data. *Extremes*, 13(4), 375-397.
- Wadsworth, J. L., & Tawn, J. A. (2012). Dependence modelling for spatial extremes. *Biometrika*, 99(2), 253-272. <https://doi.org/10.1093/biomet/asr080>

- Wadsworth, J. L., & Tawn, J. A. (2022). Higher-dimensional spatial extremes via single-site conditioning. *Spatial Statistics*, 51, 100677. <https://doi.org/10.1016/j.spasta.2022.100677>
- Yadav, R., Huser, R., & Opitz, T. (2022). A flexible Bayesian hierarchical modeling framework for spatially dependent peaks-over-threshold data. *Spatial Statistics*, 51, 100672.
- Zaheer, M., Kottur, S., Ravanbakhsh, S., Poczos, B., Salakhutdinov, R., & Smola, A. (2017). Deep Sets [NIPS 2017]. *arXiv preprint arXiv:1703.06114*. <https://arxiv.org/abs/1703.06114>
- Zeiler, M. D., & Fergus, R. (2014). Visualizing and understanding convolutional networks. *European Conference on Computer Vision*, 818-833.
- Zhang, S., Tong, H., Xu, J., & Maciejewski, R. (2019). Graph convolutional networks: a comprehensive review. *Computational Social Networks*, 6(1), 11. <https://doi.org/10.1186/s40649-019-0069-y>